北京理工大學

# 本科生毕业设计（论文）

## 搜索引导与神经网络策略蒸馏的多机器人追逃博弈研究

**Research on Multi-Robot Pursuit-Evasion Games Based on Search Guidance and Neural Policy Distillation**


学　　院：自动化学院

专　　业：自动化

班　　级：06112202

学生姓名：史锦程

学　　号：1120221902

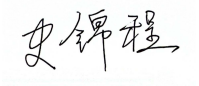
指导教师：邓方


2026 年 6 月 7 日

# 原创性声明

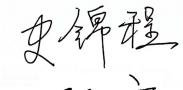
本人郑重声明：所呈交的毕业设计（论文），是本人在指导老师的指导下独立进行研究所取得的成果。除文中已经注明引用的内容外，本文不包含任何其他个人或集体已经发表或撰写过的研究成果。对本文的研究做出重要贡献的个人和集体，均已在文中以明确方式标明。

特此申明。

本人签名：  日 期： 2026年 5 月29 日

# 关于使用授权的声明

本人完全了解北京理工大学有关保管、使用毕业设计（论文）的规定，其中包括：①学校有权保管、并向有关部门送交本毕业设计（论文）的原件与复印件；②学校可以采用影印、缩印或其它复制手段复制并保存本毕业设计（论文）；③学校可允许本毕业设计（论文）被查阅或借阅；④学校可以学术交流为目的，复制赠送和交换本毕业设计（论文）；⑤学校可以公布本毕业设计（论文）的全部或部分内容。

本人签名：  日 期： 2026年 5 月29 日

指导老师签名：  日 期： 2026年 5 月29 日

# 搜索引导与神经网络策略蒸馏的多机器人追逃博弈研究

## 摘　要

随着移动机器人在复杂动态任务中的应用不断拓展，多机器人系统正由协同作业逐步发展到具有主动交互特征的对抗决策场景。追逃博弈作为多智能体对抗问题的典型形式，能够集中反映机器人团队协同、对手行为响应和实时策略生成等关键问题。针对连续空间下多机器人追逃对抗中联合动作空间维数高、纯搜索在线计算开销大以及学习策略训练稳定性不足等问题，本文以二维连续空间中的 2v2 多机器人追逃对抗场景为对象，开展基于搜索引导与神经网络策略蒸馏的多机器人对抗策略研究。

面向上述问题，本文构建了连续空间追逃任务模型，并提出一种搜索与学习融合的对抗策略生成方法。该方法以蒙特卡洛树搜索生成具有多步推演信息的专家决策样本，通过行为克隆将搜索经验蒸馏到策略网络中，实现连续动作的低时延输出；同时引入价值网络估计对抗状态的长期回报，为搜索过程中的叶节点评估提供辅助，从而减少纯随机仿真带来的计算量。在全局感知场景下，本文通过 160K 条等效对抗轨迹数据验证了方法的有效性。实验结果表明，策略网络能够学习有效的追捕与规避行为，单步推理耗时低至 0.33ms，融合策略在有限预算下提升了决策效率。进一步地，本文构建了包含语义激光雷达观测、静态障碍物遮挡和 MINCO 底层轨迹规划的局部感知追逃仿真系统。仿真结果表明，所提方法在局部观测、障碍约束和运动学约束条件下仍具有可行性。

**关键词：追逃博弈；蒙特卡洛树搜索；神经网络；策略蒸馏；行为克隆**

# Research on Multi-Robot Pursuit-Evasion Games Based on Search Guidance and Neural Policy Distillation

## Abstract

With mobile robots increasingly used in complex dynamic tasks, multi-robot systems are moving from cooperative operation to adversarial decision-making with active interactions. As a typical multi-agent adversarial problem, pursuit-evasion games involve team coordination, opponent response, and real-time strategy generation. To address the high-dimensional joint action space, high online cost of pure search, and unstable learned-policy training in continuous-space multi-robot pursuit-evasion, this thesis studies search-guided and neural-policy-distilled adversarial strategies in a 2v2 pursuit-evasion scenario in two-dimensional continuous space.

To address these issues, this thesis constructs a continuous-space pursuit-evasion model and proposes a search-learning fusion method for adversarial strategy generation. The method uses Monte Carlo Tree Search to generate expert samples with multi-step lookahead information, distilling search experience into a policy network via behavior cloning for low-latency continuous action output; meanwhile, a value network estimates long-term returns of adversarial states to assist leaf-node evaluation during searching, thereby reducing pure random simulation computations. In the global-perception scenario, 160K equivalent adversarial trajectories validate the method's effectiveness. Results show the policy network learns effective pursuit and evasion behaviors with a single-step inference time down to 0.33 ms, and the fusion strategy improves decision efficiency under limited budgets. Furthermore, a local-perception pursuit-evasion simulation system integrating semantic LiDAR, static obstacle occlusion, and MINCO low-level trajectory planning is built. Simulation results demonstrate that the proposed method remains feasible under local observations, obstacle constraints, and kinematic constraints.

**Key Words: Pursuit-Evasion Game; MCTS; Neural Network；Policy Distillation；Behavior Cloning**

# 目 录

摘 要 ..... I
Abstract ..... II
第 1 章 绪论 ..... 1
1.1 研究背景与意义 ..... 1
1.2 国内外研究现状 ..... 2
1.2.1 追逃博弈对抗与建模研究现状 ..... 2
1.2.2 基于搜索的对抗决策方法 ..... 5
1.2.3 多智能体对抗策略学习方法 ..... 5
1.2.4 搜索与学习融合方法 ..... 6
1.3 主要研究内容 ..... 7
1.4 论文结构安排 ..... 8
1.5 本章小结 ..... 9
第 2 章 理论基础 ..... 10
2.1 蒙特卡洛树搜索 ..... 10
2.1.1 置信上界及其在树搜索中的扩展 ..... 10
2.1.2 蒙特卡洛树搜索的基本流程 ..... 12
2.2 神经网络基本原理 ..... 13
2.2.1 神经元模型与神经网络结构 ..... 13
2.2.2 激活函数与神经网络训练方法 ..... 14
2.3 双策略迭代与策略蒸馏 ..... 15
2.3.1 模仿学习 ..... 15
2.3.2 双策略迭代框架 ..... 16
2.3.3 搜索策略蒸馏形式 ..... 16
2.4 本章小结 ..... 17
第 3 章 搜索引导的多智能体对抗策略算法设计 ..... 18
3.1 方法总体设计 ..... 18
3.2 基于 MCTS 的专家动作生成 ..... 19
3.2.1 搜索树的状态表示 ..... 19
3.2.2 搜索过程与动作输出 ..... 23
3.3 策略网络 ..... 25
3.3.1 策略训练样本构造 ..... 26

3.3.2 策略网络的行为克隆训练 ..... 27
3.4 价值网络 ..... 28
3.4.1 价值样本构造与网络训练 ..... 29
3.4.2 搜索过程中的价值估计 ..... 30
3.5 本章小结 ..... 31
第 4 章 面向全局感知的 2v2 追逃对抗场景建模与实验验证 ..... 32
4.1 追逃对抗场景描述 ..... 32
4.2 全局感知条件下的任务建模 ..... 32
4.2.1 状态空间与动作空间 ..... 32
4.2.2 状态转移与约束条件 ..... 33
4.2.3 奖励函数与终止判定 ..... 34
4.3 实验环境与参数设置 ..... 35
4.4 实验结果与分析 ..... 36
4.4.1 离线训练结果分析 ..... 36
4.4.2 典型对抗轨迹分析 ..... 37
4.4.3 不同决策方法对比 ..... 42
4.4.4 搜索预算对决策性能的影响 ..... 46
4.5 本章小结 ..... 48
第 5 章 面向真实场景的局部感知追逃对抗系统构建与仿真 ..... 49
5.1 局部感知追逃场景与观测建模 ..... 49
5.2 基于 MINCO 的底层轨迹规划 ..... 52
5.3 实验结果与分析 ..... 54
5.3.1 实验参数与场景设置 ..... 54
5.3.2 局部感知下的对抗轨迹分析 ..... 55
5.3.3 感知受限与障碍约束对策略的影响 ..... 57
5.4 本章小结 ..... 60
结 论 ..... 61
参考文献 ..... 63
致 谢 ..... 66

# 第 1 章 绪论

## 1.1 研究背景与意义

随着移动机器人在环境感知、定位导航、路径规划与运动控制等方面的发展，机器人系统逐步由单体作业走向多机器人协同。相较于单机器人系统，多机器人系统能够通过任务分担、并行执行和信息互补提升任务效率，并在覆盖范围、鲁棒性和复杂任务完成能力等方面表现出优势。如图1-1所示，在巡检安防、协同运输和应急救援等场景中，多机器人协同决策已成为移动机器人实际应用的重要方向。



（a）单机器人水面取样　　（b）多机器人仓库存储　　（c）多机器人火灾协助

图 1-1 移动机器人在日常生活中的实际应用

然而，现实任务环境往往并非静态、友好且可完全预测。进一步地，随着应用环境由结构化、静态场景逐步扩展到开放、动态和不确定场景，机器人系统不仅需要完成协同规划与任务执行，还需要应对具有主动行为和策略意图的外部目标。此时，决策问题不再局限于传统意义上的路径规划和轨迹跟踪，而是需要同时考虑我方动作、对手响应以及环境约束共同作用下的动态博弈过程。从理论层面看，多机器人对抗决策涉及多主体耦合、队内协同、队间博弈、长期收益评估和实时策略生成等问题；在连续状态与连续动作条件下，智能体数量增加还会导致联合动作空间迅速膨胀，使策略搜索和学习训练面临更高复杂度。因此，如何在多机器人团队层面建立合理的对抗建模方式，并在有限计算资源下实现有效求解，成为兼具理论研究价值与工程意义的重要课题。

追逃博弈是多机器人对抗决策中的典型问题形式。如图1-2所示，追逃博弈中的参与者主要分为追逐者与逃跑者，二者为实现各自目标而展开博弈。追逐者的目标是尽快捕获逃跑者，或将其驱赶至特定区域内；逃跑者则致力于避免被捕获，或尽

可能延长存活时间。追逃博弈源于捕食者与猎物之间的追逐过程，其核心在于追击方与逃避方围绕捕获、脱逃、封堵和突破等目标展开动态交互。追逃博弈中的决策需要同时考虑当前态势、未来演化以及对手可能采取的反制行为，能够集中体现多机器人对抗任务中的协同决策、对手建模和实时策略生成问题。因此，以追逃博弈为切入点研究多机器人对抗策略，不仅有助于加深对多智能体动态博弈机制的理解，也可为复杂场景下的机器人搜捕、拦截和攻防任务提供方法支撑。



（a）猎豹追击羚羊　　（b）室内机器人搜捕

图 1-2 生活中的追逃博弈

## 1.2 国内外研究现状

### 1.2.1 追逃博弈对抗与建模研究现状

追逃博弈被广泛应用于人类社会。在导航上，追逃策略可用于规划行驶路线以保证安全车距; 在治安管理上，需要合理的抓捕策略来实现对犯罪嫌疑人的追捕; 在机器人和智能控制领域上，无人机集群执行任务时，常常涉及追逃情境下的策略; 在战斗机空战 (Dogfight) 中，追击敌机、围捕目标等都可以用到追逃博弈中的策略。追逃博弈作为多智能体对抗博弈的重要分支，长期被视为刻画此类问题的经典抽象，其核心在于围绕“捕获–脱逃”这一对立目标对追逐者与逃跑者之间的动态交互过程进行统一建模[1]，如图1-3所示。

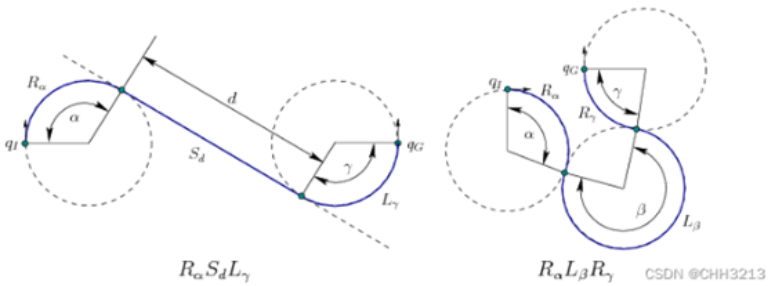
建立合适的动态模型是研究追逃博弈的第一步。Isaacs 等人[2]、Ho 等人[3]以及部分较早期研究[4]多采用一阶积分器模型，将智能体描述为速度受限、方向可控的简化运动体，以突出追逃博弈中的几何关系与策略结构。在讨论一些特殊设定时，研究者



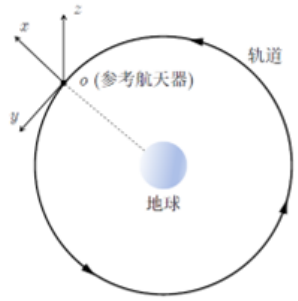

图 1-3 追逃博弈建模概况

们为了剥离非关键复杂因素、专注探索核心创新点，往往会选择采用简单动态模型。例如，Oyler 等[5]在考虑障碍物对等时线形状变化的影响时，由于一阶模型具有较为简单的运动特性，其等时线形状更加规则，因而便于分析；Garcia 等[6]在研究三维空间中的追逃博弈时指出，当空间维数增加时，一阶积分器模型仍然是追逃双方动态模型的常用选择。由此可见，一阶积分器模型因形式简洁、分析便利，在追逃博弈研究中被广泛作为基础动力学模型使用[2-6]。随着研究逐步面向真实机器人系统，一阶模型难以充分反映加速度约束、转弯半径和平台运动学特性，二阶积分器模型[7-9]、独轮车模型以及 Dubins 模型[10]等得到进一步应用，使建模能够覆盖车辆、无人机和无人艇等更接近工程实际的运动对象。近年来，随着应用领域向航空航天和海洋方向拓展，定义在 LVLH 坐标系中的航天器相对运动模型[11]、Wang 等人提出的基于生物启发的动态模型[12]、Lin 等人提出的水面无人艇模型[13]等也被引入追逃问题之中，在连续控制约束更强的场景下，相关研究还将非完整约束追逃与障碍规避统一到非线性模型预测控制框架中[14]，说明追逃博弈建模正在从简化动力系统描述逐步走向面向具体平台特性的异构建模，如图1-4所示。与此同时，面向复杂速度设定和大状态空间，追逃问题的并行化求解也得到了研究[15]；参与者数量也由早期的一对一问题[2]逐步扩展到多对一[16-18]和多对多情形[19-21]，使研究对象由单体“追击–规避”关系进一步发展为包含队内协同和队间对抗的团队博弈问题。总体来看，动态模型的演进体现了追逃研究由理论可分析性向工程真实性不断靠近的发展趋势[1]。

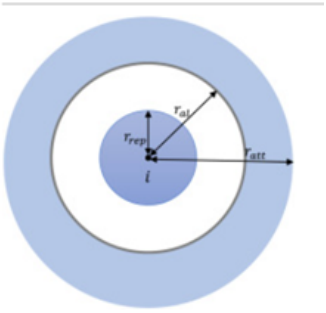
除个体动力学外，环境条件与信息获取方式也是追逃博弈建模中的关键内容。现有研究大体经历了从二维平面到三维空间[6,22]、从开阔自由空间到障碍受限区域[5]、从完全信息到不完全信息[23-24]条件下的问题拓展过程。二维平面的追逃博弈主要关注平面内追逃双方的运动轨迹和策略选择. 二维平面中计算复杂度较低、轨迹较为简




（a）Dubins 曲线模型




（b）航天器相对运动模型的 LVLH 坐标系




（c）吸引–排斥模型设定的追逃策略

图 1-4 更接近工程实际的建模

单, 平面几何的成熟理论也为追逃博弈提供了理论基础, 因此早期的追逃研究都设定在二维平面上；随着无人机、航天器等平台的发展，三维空间中的追逃对抗逐渐受到关注。与此同时，现实任务中的障碍物、边界约束、区域结构以及有限探测范围、可见性限制[25]、噪声干扰和信息时延等因素，也不断被纳入建模过程之中，使追逃问题不仅涉及双方的相对运动关系，还涉及环境结构和观测条件对博弈过程的共同作用。Karaman 等人还将在连续空间内将追逃问题视为带对手的运动轨迹规划问题[26]。这表明，追逃博弈已不再只是理想空间中的运动追逐问题，而是一类与场景约束、感知能力和信息结构密切相关的复杂对抗问题[1]。

除上述几个方面外，智能体所处的状态空间也是追逃博弈中的关键要素。根据状态空间的设定，可以把追逃博弈分为离散的和连续的。离散设定下的追逃博弈通常涉及在离散的时间空间内的追逃行为[27-28], 而连续设定则允许追逃双方在连续的时空中运动[29-31]。连续的设定有助于建立数学模型、求解 HJI 方程等。但随着追逃博弈的设定不断复杂化, 纯数学方法很多时候无法求解, 需要借助计算机仿真模拟或是强化学习等方法。但根据计算机的设计原理, 即便追逃博弈设定为连续状态, 实际在计算机中的处理都是离散化的比如图结构抽象[32-33]、多边形环境[34]或栅格空间环

境表示，使问题在结构上更加清晰。二者共同推动了追逃博弈从经典微分对策问题向现代多智能体对抗问题的拓展。

### 1.2.2 基于搜索的对抗决策方法

在能够进行模型推演的对抗场景中，基于搜索的决策方法由于能够显式刻画对手响应过程、具备较强的可解释性，并可在有限计算预算下实现对未来局势的多步推演，因而成为对抗决策研究中的一条重要技术路线。对于典型零和博弈问题，传统极小极大（minimax）方法通过在博弈树上交替求取最大收益与最小收益，在此基础上结合剪枝策略，还可以有效减少无效节点扩展，提高搜索效率。Zhang 等[35-36]围绕“最小化可探测性、最大化可见性”的对抗侦察问题，系统比较了 minimax 与蒙特卡洛树搜索在相同任务设定下的性能差异，并提出多种剪枝与树扩展控制策略，在保证求解质量的同时显著压缩了搜索规模，为机器人对抗场景中的搜索式决策提供了较为清晰的研究范式。

随着状态空间与动作空间持续扩大，传统依赖较完整树展开的搜索方法逐渐面临计算负担迅速上升的问题。相较之下，蒙特卡洛树搜索 (Monte Carlo Tree Search，MCTS) 逐渐成为复杂对抗决策问题中的代表性方法。Bonanni 等[37]进一步将 MCTS 与速度障碍方法相结合，尝试在动态环境中同时兼顾对抗推演与安全运动规划，从而拓展了树搜索方法在复杂机器人决策问题中的适用范围。

然而，当对抗问题由 1v1 扩展到 2v2 乃至更大规模时，搜索方法面临的关键困难在于联合动作空间迅速膨胀，进而导致搜索树分支因子显著增大，使在线求解的计算开销急剧上升。针对这一挑战，Li 等[38]在空战对抗研究中提出分布式双博弈树 MCTS 方法，通过高层任务分解、动作约束以及双树结构设计减少无效扩展，从而在一定程度上缓解了多主体同步对抗中的搜索压力。总体而言，现有基于搜索的对抗决策研究已经形成了较为丰富的方法积累，能够为对抗任务提供质量较高、逻辑清晰的决策基线；但其在多机器人团队对抗中的实时部署能力仍然受到较大限制，这也进一步推动了后续搜索与学习融合方法的发展[35,37-38]。

### 1.2.3 多智能体对抗策略学习方法

相较于依赖显式模型推演的搜索方法，强化学习（Reinforcement Learning, RL）及多智能体强化学习（Multi-Agent Reinforcement Learning, MARL）通过函数逼近直接学习从状态到动作的映射关系，具有推理速度快、表达能力强以及适合高频在线

执行等优势，因此在多机器人任务中受到广泛关注。Chen 等[39]针对可见性持续监测问题开展研究，将未被监测时间的累积惩罚纳入学习目标，并引入图注意力机制实现多智能体之间的信息共享，实验结果表明，该方法相较于非强化学习基线能够取得更优的持续监测效果，并表现出一定的协同行为涌现特征。类似地，Qin 等[40]在多智能体协同搜索静止目标的研究中，通过融合局部概率地图与邻居信息构造状态输入，并结合稳定训练机制提升学习性能，在平均搜索步数和成功率等指标上优于传统覆盖控制与随机策略。

随着任务规模扩大，多智能体策略学习面临的核心问题逐渐由“能否学到策略”转向“所学策略能否扩展、迁移并保持稳定有效”。在这一背景下，策略的可扩展性与泛化能力成为学习方法走向实际应用的关键。Hsu 等[41]基于去中心化部分可观测建模，利用注意力机制对价值函数进行参数化，并采用掩码式训练实现从小规模场景向大规模场景的迁移，实验表明该方法能够扩展到上千智能体的控制任务，体现出较好的规模泛化能力。在追逃对抗的学习化研究中，Souidi 等[42]将组织架构、任务分配与底层动作学习相结合，通过联盟形成等机制提升团队追捕能力，展示了结构化组织的方法特点。与此同时，Shi 等[43]从鲁棒规划角度研究了对抗环境中的路径安全问题。这些研究表明，多智能体策略学习并不只是单一主体的策略优化问题，而是需要同时处理多主体耦合、规模变化以及对手行为扰动所带来的复杂挑战。

需要指出的是，在显式对抗任务中，纯 MARL 方法虽然具有较高的执行效率，但在训练稳定性和策略质量方面仍面临不少困难。Agmon[44]在对抗环境下机器人策略行为的综述中指出，对抗任务中的关键难点在于对手具有策略性和反制能力，这使得机器人决策问题与一般协同任务存在本质差异。而纯强化学习方法往往容易受到奖励稀疏、训练样本开销大以及自博弈过程不稳定等问题影响[41-42]。因此，虽然多智能体学习为对抗决策提供了高效部署的可能路径，但仅依赖纯学习方法往往难以同时兼顾策略质量、训练稳定性与工程可实现性，这也使越来越多研究开始转向搜索引导下的策略学习与蒸馏方法。

### 1.2.4 搜索与学习融合方法

针对搜索方法“对抗推演能力强但在线开销较高”与学习方法“推理效率高但训练稳定性不足”之间的矛盾，近年来对抗决策研究逐渐形成了搜索与学习融合的发展路线。

在代表性工作中，Riviere 等[45]提出的神经树扩展（Neural Tree Expansion, NTE）方法，将 AlphaZero 式“搜索–学习”闭环进一步推广到多机器人非合作规划场景。该方法利用高预算专家 MCTS 生成示范数据，并通过学习得到的网络为在线规划提供动作候选和先验引导，从而在有限计算资源条件下兼顾规划质量与在线决策频率。类似地，Zhang 等[46]在空战机动决策研究中，将深度强化学习与 MCTS 相结合，通过自博弈生成“状态–动作–结果”样本，并设计适用于连续动作空间的搜索机制，使搜索与学习在迭代过程中形成策略改进闭环，从而逐步提升对抗决策性能。

总的来看，融合方法的发展主线已经由早期利用网络评估引导搜索的方式逐步走向网络生成动作候选或策略先验，搜索进行筛选与推演，再利用对抗数据反向训练网络的闭环模式[45-46]，为多机器人团队对抗问题提供更具现实可行性的解决路径。

尽管如此，现有搜索与学习融合研究仍存在若干有待进一步深入的问题。首先，高质量搜索样本的生成成本通常较高，随着对抗规模扩大，专家数据获取的计算代价会显著增加；其次，在搜索策略向神经网络迁移的过程中，策略性能往往会受到观测信息压缩、函数逼近误差以及训练分布偏差等因素影响而出现下降。因此，围绕搜索引导、离线学习与策略蒸馏开展研究，不仅具有明确的方法合理性，也构成了当前多机器人对抗决策研究的重要发展方向。

## 1.3 主要研究内容

面向二维连续空间下的 2v2 多机器人追逃对抗问题，本文围绕环境建模、搜索决策和策略蒸馏展开研究，整体研究框架如图1-5所示。本文的主要研究内容如下：

（1）设计连续空间下的多机器人追逃对抗模型。针对 2v2 追逃任务中多机器人连续运动、团队协同和队间对抗等特点，建立包含状态表示、连续动作空间、状态转移、捕获判定和终止条件的任务模型；围绕追捕方快速捕获和逃逸方延长存活时间的目标，设计包含捕获收益、存活收益和越界惩罚的奖励函数，并引入一对一兑子机制刻画捕获后的智能体失活过程。该模型为搜索推演、策略学习和仿真实验提供了统一的环境基础。

（2）设计面向连续联合动作空间的搜索引导策略生成算法。针对多机器人对抗中联合动作维数高、纯搜索计算开销大的问题，本文以蒙特卡洛树搜索为专家决策生成器，设计联合动作采样、渐进扩展、交替评价和根节点动作选择等搜索规则，使搜索器能够在有限预算下对候选联合动作进行多步推演，并生成具有长期收益信息

的专家动作。在此基础上，通过行为克隆将专家动作蒸馏到策略网络中，实现搜索经验向低时延神经网络策略的迁移。

（3）构建搜索–学习融合机制并验证其有效性。针对纯策略网络长期规划能力不足、纯搜索在线耗时较高的问题，本文进一步引入价值网络估计对抗状态的长期回报，并用于辅助搜索过程中的叶节点评估。实验结果表明，该方法能够在有限搜索预算下保持较好的对抗性能，降低纯搜索带来的在线计算压力；在引入语义激光雷达、障碍物遮挡和 MINCO 轨迹规划的局部感知场景中，该方法仍能生成合理的多机器人对抗行为。

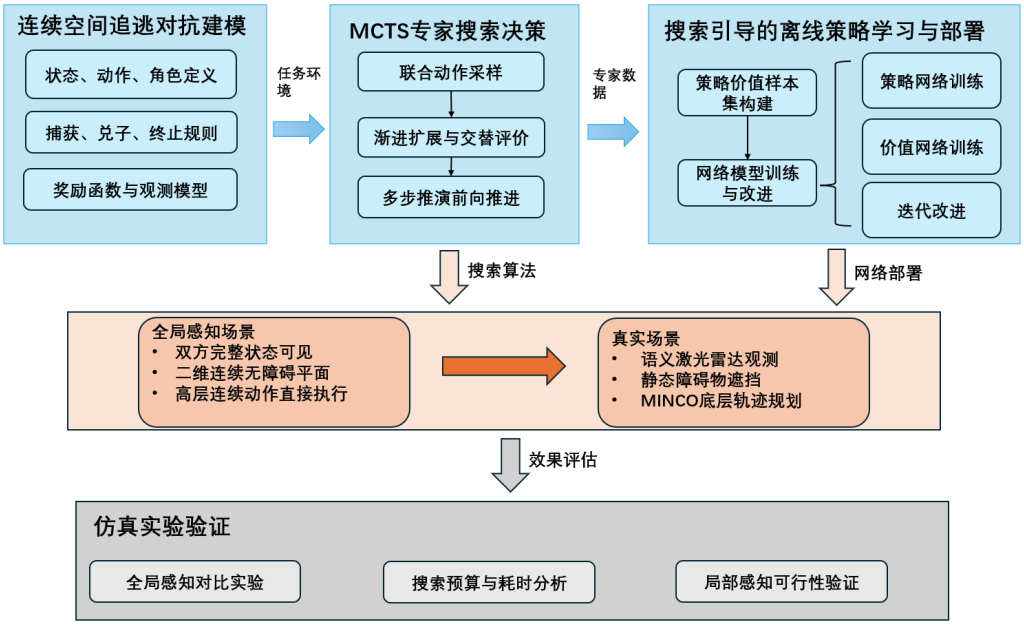



图 1-5 研究内容基本框架

## 1.4 论文结构安排

本文围绕二维连续空间下的 2v2 多机器人追逃对抗问题展开研究，按照理论基础—算法设计—全局感知实验—局部感知部署仿真的思路组织全文。各章内容安排如下：

第 1 章为绪论，介绍研究背景与意义，综述追逃博弈建模、搜索式对抗决策、多智能体策略学习以及搜索学习融合方法的研究现状，并概括本文主要研究内容。

第 2 章为理论基础，介绍本文涉及的蒙特卡洛树搜索、神经网络函数逼近、模仿学习、双策略迭代和搜索策略蒸馏等基础内容。

第 3 章为搜索引导的多智能体对抗策略算法设计，给出由专家搜索器、策略网络和价值网络组成的搜索学习融合框架，并说明专家动作生成、策略网络训练和价值网络辅助搜索的具体方法。

第 4 章为面向全局感知的追逃对抗场景建模与实验验证，建立全局感知无障碍条件下的 2v2 追逃任务模型，并通过训练结果、典型轨迹、方法对比和搜索预算实验验证所提方法的有效性。

第 5 章为面向真实场景的局部感知追逃对抗系统构建与仿真，在全局感知模型基础上引入语义激光雷达、静态障碍物和 MINCO 底层轨迹规划，分析局部观测和运动约束对策略执行效果的影响。

最后对全文工作进行总结，并讨论本文方法的不足与后续研究方向。

## 1.5 本章小结

本章主要介绍了多机器人对抗决策及追逃博弈的研究背景与实际应用意义，并对连续空间追逃博弈建模、基于搜索的对抗决策方法、多智能体对抗策略学习方法以及搜索与学习融合方法等国内外的研究现状进行了全面综述。最后，阐述了本文的主要研究内容与全书的结构安排，为后续章节开展多机器人对抗策略的算法设计与实验验证奠定了方法学和背景基础。

# 第 2 章 理论基础

## 2.1 蒙特卡洛树搜索

蒙特卡洛树搜索是一种基于随机采样和树结构统计的序贯决策方法。算法从当前状态出发构建搜索树，通过反复模拟后续动作序列估计不同分支的长期收益，并在有限计算预算下选择较优动作。与 Minimax 及 Alpha-Beta 剪枝等固定深度搜索方法相比，MCTS 不要求完整展开博弈树，而是依据搜索过程中积累的访问次数和价值统计，将更多计算资源分配到潜在价值较高的分支，因此适用于状态空间大、决策深度长且难以解析求解的序贯决策问题。

MCTS 的思想来源于蒙特卡洛采样：当目标量难以直接计算时，可通过多次随机试验近似其期望。应用到决策问题时，算法从某一状态开始模拟若干后续动作并统计回报，以近似评价当前动作优劣。Coulom 对选择性扩展和回传算子进行了系统讨论[47]；Chaslot 等提出渐进策略，通过随访问次数逐步增加候选动作缓解大分支因子问题[48]；Auger 等将置信上界树扩展到连续动作空间，提出连续置信上界树并分析了一致性条件[49]。对于连续或高维动作任务，MCTS 通常需要结合策略先验、渐进扩展或价值函数近似，以减少无效采样并提高有限预算下的搜索质量。

### 2.1.1 置信上界及其在树搜索中的扩展

树搜索中的节点选择需要在“利用已有高收益分支”和“探索访问次数较少分支”之间取得平衡。置信上界 (Upper Confidence Bound, UCB) 最初用于多臂老虎机问题，其核心是在平均收益估计上加入探索奖励。设第 $i$ 个动作已被选择 $N_i$ 次，平均收益为 $\bar{X}_i$，所有动作总选择次数为 $N$，则

$$i^* = \arg\max_i \left( \bar{X}_i + c\sqrt{\frac{\ln N}{N_i}} \right), \tag{2-1}$$

其中，第一项为利用项，第二项为探索项，$c$ 控制探索强度。

置信上界树 (Upper Confidence Bound applied to Trees, UCT) 将上述思想用于搜索树节点选择，如图2-1所示。搜索树中每个节点表示一个状态，每条分支表示一个可

执行动作，父节点下的动作分支可视为多臂老虎机中的不同“臂”。UCT 常用准则为

$$a^{*}=\arg\max_{a}\left[Q(s,a)+c\sqrt{\frac{\ln N(s)}{N(s,a)}}\right], \tag{2-2}$$

其中，$Q(s,a)$ 为在状态 $s$ 下执行动作 $a$ 的平均价值估计，$N(s)$ 与 $N(s,a)$ 分别为状态节点和动作分支的访问次数。该形式将蒙特卡洛采样、选择性扩展和统计回传统一起来，使搜索资源能够依据访问统计自适应分配[47]。

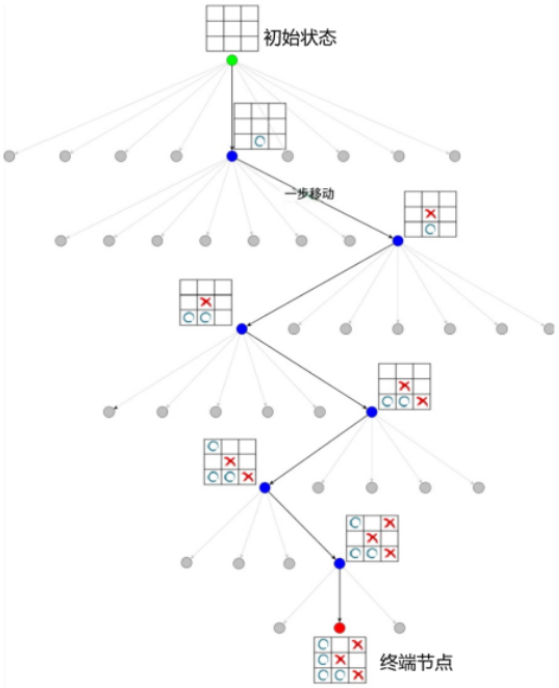



图 2-1 UCT 算法用于井字棋的搜索过程示意图

在 UCT 的基础上，PUCT 引入策略先验 $P(s,a)$，使已有策略模型能够影响搜索方向。其典型形式为

$$a^{*}=\arg\max_{a}\left[Q(s,a)+c_{\text{puct}}P(s,a)\frac{\sqrt{N(s)}}{1+N(s,a)}\right]. \tag{2-3}$$

相较于仅依赖访问统计的 UCT，PUCT 能够优先扩展先验概率较高且历史价值较好的动作分支，在搜索预算有限时更适合与神经网络策略结合。对于连续动作或候选动作极多的场景，渐进扩展并不在节点初次访问时枚举全部动作，而是随访问次数增加逐步引入新分支，从而兼顾有限候选动作的深度评估和连续动作空间的广度探

索[48-49]。

### 2.1.2 蒙特卡洛树搜索的基本流程

MCTS 算法能够避免对大规模搜索空间进行完全遍历，而是通过在搜索树的局部区域进行采样来评估不同动作的潜在价值。在 MCTS 中，树中的节点通常表示决策过程中的一个可能状态，节点价值由从该状态出发多次模拟所得结果的统计信息进行估计。算法从根节点开始，在给定搜索预算内不断重复选择、扩展、仿真和回传四个阶段，使搜索树逐步生长并积累节点统计量。一次完整迭代如图2-2所示。

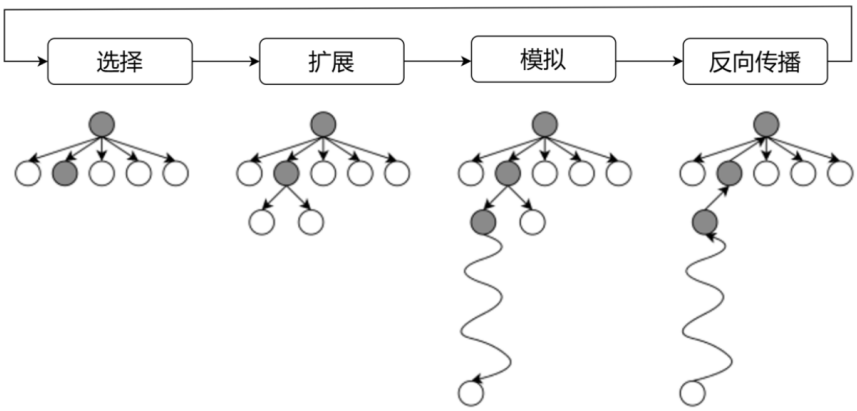



图 2-2 MCTS 算法基本步骤

选择阶段根据 UCT 或 PUCT 准则在已有树中逐层选择子节点，直到到达未完全扩展节点或终止节点；扩展阶段从该节点生成新的动作分支和后继状态；仿真阶段从新节点继续前向推演，直至终止状态或最大仿真深度，并计算回报；回传阶段将回报沿访问路径反向传播，更新访问次数和累计价值。设节点 $n$ 的访问次数、累计价值和平均价值分别为 $N(n)$、$W(n)$ 和 $Q(n)$，本次回报为 $G$，则

$$N(n) \leftarrow N(n) + 1, \tag{2-4}$$

$$W(n) \leftarrow W(n) + G, \tag{2-5}$$

$$Q(n) = \frac{W(n)}{N(n)}. \tag{2-6}$$

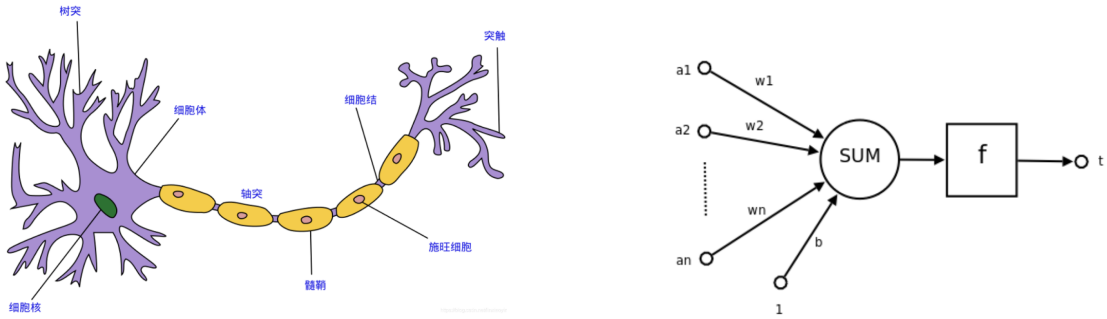
搜索结束后，根节点通常选择访问次数最多或平均价值最高的子节点对应动作。

MCTS 具有 Anytime 特性，即任意计算预算下均可输出当前估计结果，并随搜索时间增加逐步改善决策质量。

## 2.2 神经网络基本原理

神经网络是一类由大量简单计算单元连接而成的函数逼近模型，通过多层线性变换和非线性映射学习输入与输出之间的复杂关系。在对抗决策任务中，策略函数和价值函数通常难以写成显式解析式，因此可用神经网络分别表示状态到动作的映射关系，以及状态或动作的长期价值估计。

### 2.2.1 神经元模型与神经网络结构




（a）生物神经元示意图　　（b）人工神经元示意图

图 2-3 生物神经元与人工神经元

人工神经元可视为对输入特征进行加权求和、加入偏置并经过激活函数输出的计算单元。多个神经元按层连接后形成前馈神经网络，其输入层接收状态或观测特征，隐藏层完成非线性特征变换，输出层根据任务输出动作、价值或其他预测量。典型结构如图2-4所示。

对于包含 $L$ 层的前馈网络，设输入为 $x$，第 $l$ 层权重矩阵和偏置向量为 $W^{(l)}$ 和 $b^{(l)}$，前向传播可写为

$$h^{(0)} = x, \tag{2-7}$$

$$h^{(l)} = f\left(W^{(l)} h^{(l-1)} + b^{(l)}\right), \quad l = 1, \cdots, L-1, \tag{2-8}$$

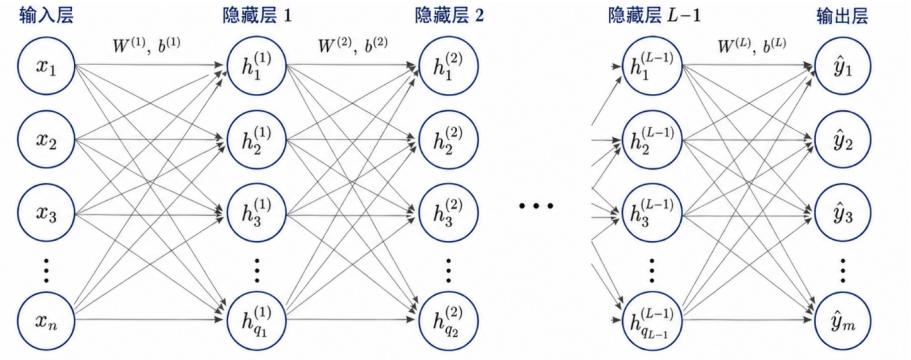


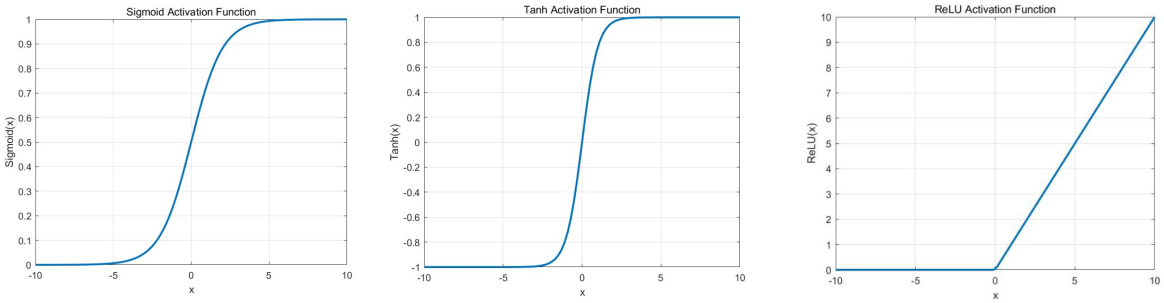

图 2-4 前馈神经网络结构示意图

$$\hat{y} = W^{(L)} h^{(L-1)} + b^{(L)}. \tag{2-9}$$

其中，$h^{(l)}$ 为第 $l$ 层输出，$\hat{y}$ 为网络最终预测结果。隐藏层数量和每层节点数共同决定参数规模与表达能力，需要根据输入维度、样本规模和任务复杂度设置。

### 2.2.2 激活函数与神经网络训练方法

激活函数用于引入非线性表达能力，否则多层线性运算仍等价于单个线性变换。常见激活函数包括 Sigmoid、Tanh 和 ReLU，函数图像如图2-5所示。




（a）Sigmoid 函数图像　　（b）Tanh 函数图像　　（c）ReLU 函数图像

图 2-5 常见激活函数图像

三类函数可写为

$$\text{Sigmoid}(x) = \frac{1}{1+e^{-x}}, \qquad \text{Tanh}(x) = \frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}, \qquad \text{ReLU}(x) = \max(0, x). \tag{2-10}$$

Sigmoid 输出范围为 $(0, 1)$，适合概率或归一化输出；Tanh 输出范围为 $(-1, 1)$，具有零中心特性；ReLU 形式简单、计算量小，在多层前馈网络中应用广泛。Sigmoid

与 Tanh 在大幅值输入下容易饱和，ReLU 在长期负输入时可能出现神经元失活。

神经网络训练一般包括前向传播、损失计算、反向传播和参数更新四步，如图2-6所示。训练效果受网络层数、隐藏层规模、激活函数、损失函数和优化方法等因素影响。对抗决策中的策略网络和价值网络均基于该训练流程进行参数学习。

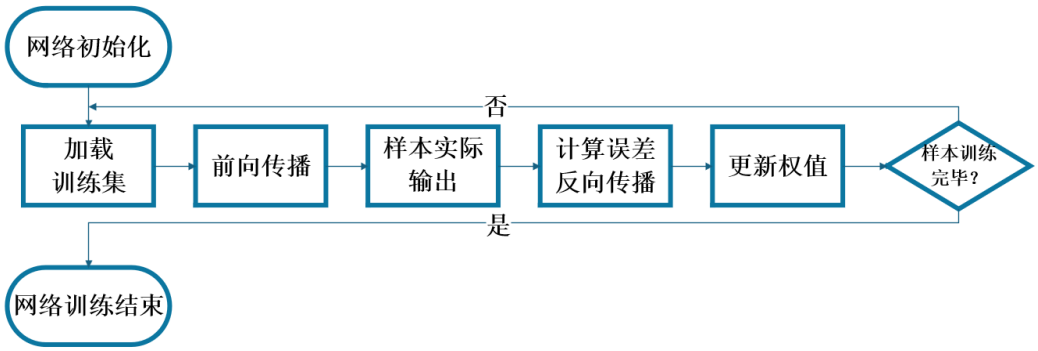



图 2-6 神经网络训练流程图

## 2.3 双策略迭代与策略蒸馏

蒙特卡洛树搜索具有多步前向推演能力，但计算开销较大；神经网络策略前向推理速度快，但单独训练时容易受到样本质量、奖励稀疏和训练不稳定影响。双策略迭代 (Dual Policy Iteration, DPI) 将二者结合：慢速非反应式策略通过搜索或规划生成局部专家决策，快速反应式策略通过监督学习吸收专家知识，并在后续搜索中提供动作先验、默认策略或价值估计。

### 2.3.1 模仿学习

模仿学习 (Imitation Learning, IL) 利用专家示范训练决策策略。设专家策略为 $\pi_E$，待学习策略为 $\pi_\theta$，专家在观测 $o_i$ 下给出动作 $a_i^E$，示范数据集为

$$\mathcal{D}_E = \left\{ (o_i, a_i^E) \right\}_{i=1}^{N}. \tag{2-11}$$

对应的一般监督学习目标为

$$\theta^* = \arg\min_{\theta} \frac{1}{N} \sum_{i=1}^{N} \ell\left(\pi_\theta(o_i), a_i^E\right). \tag{2-12}$$

行为克隆 (Behavior Cloning, BC) 是模仿学习的直接形式。对于连续动作空间，可用均方误差拟合专家动作：

$$L_{\mathrm{BC}} = \frac{1}{N}\sum_{i=1}^{N} \left\| \pi_\theta(o_i) - a_i^E \right\|_2^2 . \tag{2-13}$$

模仿学习的效果受专家质量和示范数据覆盖范围影响，单步动作误差较小并不必然保证长期收益最优，因此通常需要与搜索、规划或在线数据更新机制结合。

### 2.3.2 双策略迭代框架

记快速反应式策略为 $\pi_n$，慢速非反应式策略为 $\eta_n$，下标 $n$ 表示迭代轮次。DPI 可抽象为两个交替步骤。首先在当前策略诱导的状态分布附近通过搜索、动态规划或模型预测控制构造改进策略：

$$\eta_n \approx \mathrm{Improve}(\pi_n). \tag{2-14}$$

随后将 $\eta_n$ 的决策知识迁移到反应式策略中。若 $\eta_n$ 能输出动作分布，可采用分布匹配更新：

$$\pi_{n+1} = \arg\min_{\pi\in\Pi} \mathbb{E}_{s\sim d_{\pi_n}} \left[ D\left(\eta_n(\cdot|s), \pi(\cdot|s)\right) \right], \tag{2-15}$$

其中，$d_{\pi_n}$ 为当前反应式策略诱导的状态分布，$D(\cdot,\cdot)$ 为策略差异度量。若搜索只输出确定性专家动作，则该过程退化为状态–动作监督学习。

### 2.3.3 搜索策略蒸馏形式

当非反应式策略由树搜索实现时，根节点的动作访问次数、动作价值或最终专家动作都可作为教师信号。设搜索器在状态 $s_i$ 下得到候选动作集合 $\mathcal{A}_i$，动作 $a$ 的访问次数为 $N_i(a)$，则访问次数可归一化为搜索策略分布：

$$\eta(a|s_i) = \frac{N_i(a)^{1/\tau}}{\sum_{a'\in\mathcal{A}_i} N_i(a')^{1/\tau}}, \tag{2-16}$$

其中，$\tau$ 为温度系数。若学生策略输出动作分布，可采用 KL 散度蒸馏：

$$L_{\mathrm{search}} = \frac{1}{N}\sum_{i=1}^{N} D_{\mathrm{KL}}\left(\eta(\cdot|s_i) \,\|\, \pi_\theta(\cdot|o_i)\right). \tag{2-17}$$

连续动作空间通常难以形成完整概率分布，可将根节点访问统计或价值统计转化为确定性专家动作，再采用动作回归损失训练学生策略。搜索策略蒸馏的作用是将高开销搜索中的长期推演结果压缩到低时延神经网络中，使训练后的网络既能直接决策，也能在后续搜索中提供动作先验或价值估计。

## 2.4 本章小结

本章系统阐述了本文研究所依托的理论基础，介绍了蒙特卡洛树搜索的基本思想，说明了前馈神经网络的基本结构、常见激活函数的数学特性以及网络训练的标准流程，探讨了模仿学习与行为克隆机制，并给出了双策略迭代框架和树搜索策略的蒸馏形式。上述基础理论为第三章构建搜索引导的多机器人对抗策略算法提供了核心支撑。

# 第 3 章 搜索引导的多智能体对抗策略算法设计

第二章已经介绍了此算法涉及的基础理论，包括蒙特卡洛树搜索、神经网络以及模仿学习与策略蒸馏等内容。在此基础上，第三章进一步给出对抗策略算法的具体设计。

## 3.1 方法总体设计

针对多智能体对抗任务中连续动作决策的高维度与非平稳性难题，本章提出一种基于搜索引导与模仿学习相结合的总体算法框架。如图3-1该方法以蒙特卡洛树搜索（MCTS）作为高质量专家示范的来源，利用神经网络强大的函数逼近能力，通过模仿学习机制实现专家经验的离线迁移与在线部署。

本文算法面向的是连续空间下的多智能体追逃对抗环境。智能体的位置、相对关系和动作取值均具有连续性。时间上采用离散时间，在固定决策周期下进行离散时序决策。具体的状态表示将在第四章和第五章结合全局感知与局部感知场景分别给出。

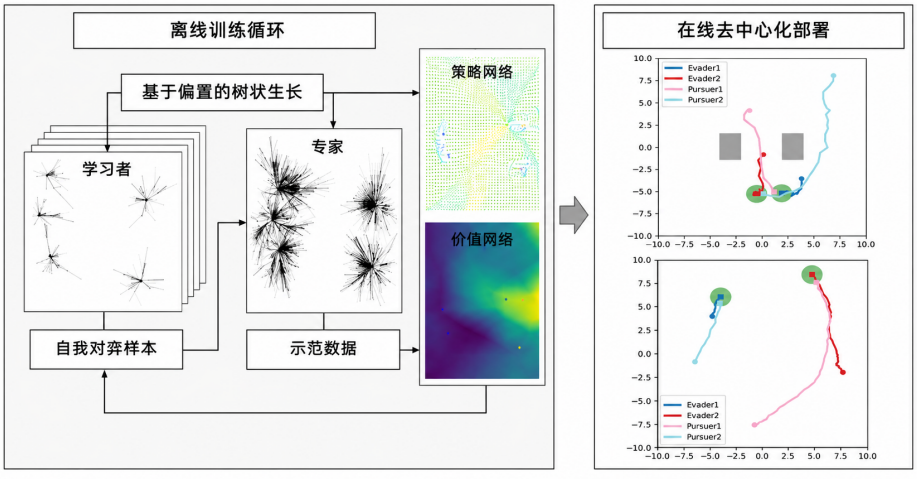



图 3-1 总体方法流程

从功能结构看，算法由专家搜索模块、策略网络模块和价值网络模块三个部分组成。专家搜索模块以当前对抗状态作为搜索根节点，利用 MCTS 从当前状态开始

模拟多种后续对抗过程，生成专家动作标签和长期回报样本，并分别用于训练策略网络与价值网络。策略网络模块以智能体观测编码为输入，通过行为克隆学习专家搜索器的动作选择规律；价值网络模块用于估计给定对抗状态下的长期回报，并在搜索过程中为叶节点提供近似价值评估，以减少随机动作带来的计算开销。

在运行机制上，算法包括离线训练和在线决策两个阶段。离线阶段以环境交互轨迹中的真实可达状态为起点，调用高预算 MCTS 生成专家动作和回报样本，并分别用于训练策略网络与价值网络。在线阶段则将当前对抗状态输入计算预算首先的搜索器，由策略网络提供候选动作先验，由价值网络辅助叶节点评估，使搜索过程能够集中于更具潜在价值的动作分支。

## 3.2 基于 MCTS 的专家动作生成

树搜索模块的作用是在给定对抗状态下生成质量较高的专家动作。搜索器以当前状态作为根节点，在有限搜索预算内不断扩展搜索树，并利用节点访问次数、累计价值和动作先验等信息逐步筛选更有潜力的动作分支。搜索结束后，根节点下的动作统计结果被用于输出当前时刻的专家动作，该动作随后作为策略网络训练的监督标签。

与普通单智能体树搜索相比，2v2 对抗任务中的搜索节点不仅需要保存环境状态，还需要考虑当前决策方、队伍动作以及联合动作构造等信息。搜索树的每一次扩展都对应一次对抗状态的前向推进，所以节点状态组织和动作输出方式直接影响后续专家样本的质量。

### 3.2.1 搜索树的状态表示

在树搜索过程中，针对当前决策队伍分别建立搜索树，每次搜索以当前真实对抗状态作为根节点，树中边表示候选联合动作，子节点表示执行该动作后的后继状态。搜索树的深度与双方轮次对应，偶数层保持根节点队伍的评价视角，奇数层切换为对手队伍的评价视角。每个节点表示对抗推演过程中的一个中间状态。设节点 $n$ 对应的环境状态为 $s_n$，搜索深度为 $d_n$，节点访问次数为 $N_n$，子节点集合为 $\mathcal{C}_n$。由于多智能体对抗任务中不同智能体具有各自的收益反馈，节点中保存的价值信息采用向量形式表示。节点 $n$ 可抽象定义为一个元组：

$$n = (s_n, \mathbf{a}_{p\to n}, d_n, N_n, \mathbf{W}_n, \mathbf{Q}_n, \mathcal{C}_n)\,. \tag{3-1}$$

式中 $\mathbf{a}_{p\to n}$ 表示由父节点转移至当前节点所执行的联合动作；$\mathbf{W}_n$ 表示节点累计价值向量，$\mathbf{Q}_n$ 表示节点平均价值向量。若环境中共有 $N_r$ 个智能体，则有：

$$\mathbf{W}_n, \mathbf{Q}_n \in \mathbb{R}^{N_r}. \tag{3-2}$$

当节点已经被访问过时（$N_n > 0$），其平均价值向量由累计价值向量与访问次数计算得到：

$$\mathbf{Q}_n = \frac{\mathbf{W}_n}{N_n}. \tag{3-3}$$

当节点尚未被访问时，$N_n = 0$，该节点的平均价值不参与当前分支的选择比较。随着搜索迭代的不断进行，节点访问次数与累计价值向量被持续更新，平均价值向量将逐渐逼近该节点状态下各智能体的真实后续收益期望。

根节点表示当前真实的对抗状态，记为 $s_0$。搜索器从根节点出发，在有限计算预算内对不同动作分支进行试探、扩展与回传更新。对于父节点 $n$ 及其子节点 $c \in \mathcal{C}_n$，子节点对应的状态由父节点状态和一组联合动作共同决定：

$$s_c = F(s_n, \mathbf{a}_{n\to c}), \tag{3-4}$$

其中，$F(\cdot)$ 表示环境状态转移函数，$\mathbf{a}_{n\to c}$ 表示从节点 $n$ 转移到子节点 $c$ 时所执行的联合动作。

在 2v2 对抗任务中，环境状态的转移由双方队伍的完整联合动作共同驱动。搜索树中的每条边对应一组完整的联合动作，而非单一智能体的动作；子节点则表示执行该联合动作后衍生出的新局势状态。设四个智能体的动作分别为 $a^1, a^2, a^3, a^4$，其中 $a^1, a^2$ 属于逃逸方，$a^3, a^4$ 属于追击方，则系统的联合动作向量可表示为：

$$\mathbf{a} = \left(\mathbf{a}^{(1)}, \mathbf{a}^{(2)}\right) = \left((a^1, a^2), (a^3, a^4)\right). \tag{3-5}$$

在搜索过程中，当前搜索层所关注的评价方由根节点决策方和搜索深度共同确定。如图3-2所示对于 2v2 场景，可用两个独立的索引分别代表双方队伍。设根节点

对应的评价方索引为 $\rho_0$，其对手方索引为 $\bar{\rho}_0$，则深度为 $d_n$ 的节点可采用如下交替评价机制：

$$\rho_n = \begin{cases} \rho_0, & d_n \bmod 2 = 0, \\ \bar{\rho}_0, & d_n \bmod 2 = 1. \end{cases} \tag{3-6}$$

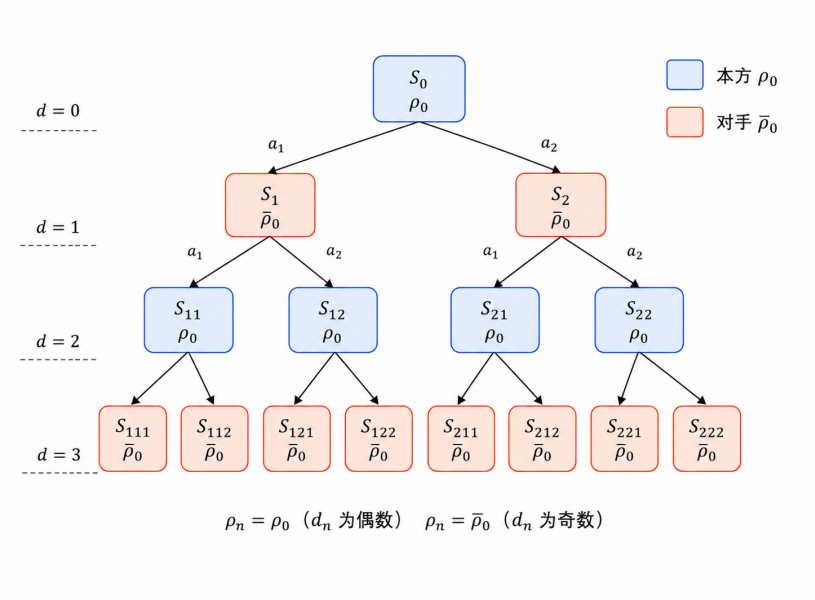



图 3-2 搜索树层级与双方评价轮次关系示意图

在进行动作分支选择时，搜索器并不直接比较完整的价值向量 $\mathbf{Q}_n$，而是根据当前评价方 $\rho_n$ 提取出对应的价值标量分量 $Q_n^{(\rho_n)}$ 参与计算。通过这种方式，搜索树虽以完整联合动作作为状态转移基础，但在不同搜索深度上能够交替最大化双方队伍的收益，使推演过程严格遵循对抗任务的非合作博弈特性。

此外，由于任务的动作空间为连续空间，搜索器难以像传统离散动作决策那样进行全节点枚举。因此，每个节点仅维护有限数量的候选联合动作。对节点 $n$ 而言，其已生成的候选动作集合可由连接至子节点的边动作表示：

$$\mathcal{A}(n) = \{\mathbf{a}_{n\to c} \mid c \in \mathcal{C}_n\}. \tag{3-7}$$

为了在连续空间中有效控制树的分支规模，搜索器采用渐进扩展机制（Progressive Widening）动态限制子节点数量。设节点 $n$ 当前允许扩展的最大子节点数为

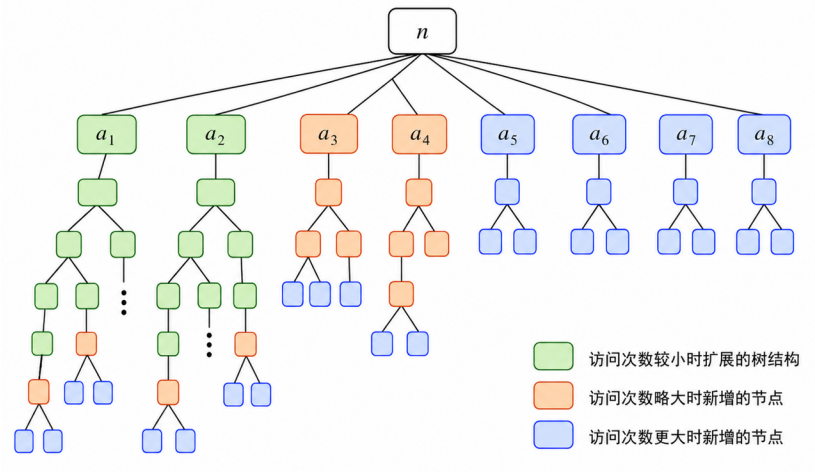
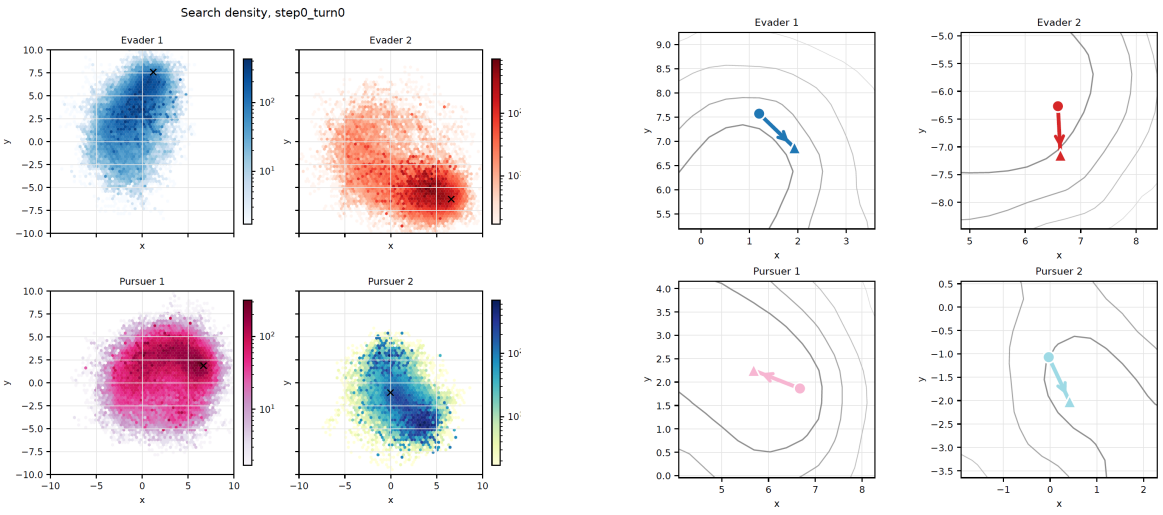



图 3-3 渐进式扩展算法示意图

$M(n)$，则有：

$$M(n) = \lceil C_{\text{pw}} N_n^{\alpha_{\text{pw}}} \rceil , \tag{3-8}$$

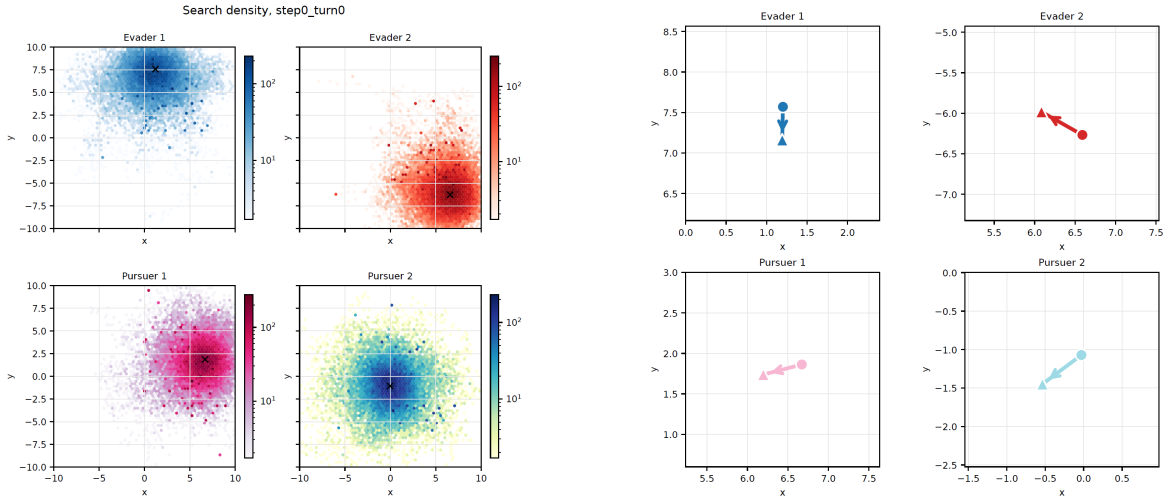
其中，$C_{\text{pw}}$ 和 $\alpha_{\text{pw}}$ 为渐进扩展超参数。如图3-3所示，当节点访问次数较少时，搜索器仅保留少量候选动作以集中算力进行纵深探索；随着访问次数增加，允许扩展的子节点规模逐步扩大，从而在有限计算预算下实现对连续动作空间的高效近似探索。




（a）有网络引导分布示例　　（b）有网络引导下的下一步动作输出

图 3-4 蒙特卡洛树搜索过程中子节点的空间分布

在候选动作生成环节，搜索器按照概率 $1-\beta$ 从连续动作空间中均匀采样，以概




（a）无网络引导分布示例　　（b）无网络引导的下一步动作输出

图 3-5 蒙特卡洛树搜索过程中的空间分布与探索深度分析

率 $\beta$ 利用网络输出的动作分布替代盲目采样，从而生成受先验引导的联合动作。如图 3-4与3-5所示，其展示了一个典型对抗状态下分别取概率 $\beta = 0.5$ 和 $\beta = 0$ 时的搜索密度分布结果，图中黑色的叉号为根节点位置。可以看出，相较于无网络引导，有网络输出引导的搜索样本并非在动作空间内均匀散布，而是逐渐集中于若干潜在高价值区域。这一设计既保留了搜索对未知空间的探索能力，又使树能够向高战术价值区域倾斜，为后续基于价值和访问次数的分支抉择提供了高质量候选池。

### 3.2.2 搜索过程与动作输出

在完成根节点初始化后，搜索器在给定搜索预算内对搜索树进行多轮模拟。每轮模拟均从根节点开始，沿搜索树向下推进，并根据当前节点的扩展情况执行分支选择或新节点扩展。当搜索过程到达最大深度、终止状态或尚未完全展开的节点时，算法对该节点进行估值，并将估值结果沿访问路径回传，用于更新沿途节点的访问次数和价值统计。总体而言，一次搜索迭代包括分支选择、节点扩展、叶节点估值和路径回传四个步骤。

**1. 分支选择**

设当前节点为 $n$，其子节点为 $c \in \mathcal{C}_n$。当节点已经扩展出可供选择的候选分支时，搜索器根据当前评价方 $\rho_n$ 对子节点进行选择。具体实现中采用带探索项的置信

上界准则，子节点 $c$ 的选择分数可写为

$$U(n,c;\rho_n)=Q_c^{(\rho_n)}+C_{\exp}\sqrt{\frac{\max(1,N_n)^{\alpha_{\exp}}}{N_c}}. \tag{3-9}$$

其中，$Q_c^{(\rho_n)}$ 表示子节点 $c$ 在当前评价方 $\rho_n$ 上的平均价值分量，$N_n$ 和 $N_c$ 分别表示父节点和子节点的访问次数，$C_{\exp}$ 与 $\alpha_{\exp}$ 为探索项超参数。该准则由价值项和探索项共同构成：价值项倾向于选择历史收益较高的分支，探索项则鼓励访问次数较少的分支继续被尝试。

**2. 节点扩展**

若当前节点尚未达到允许扩展的候选分支数量，搜索器则执行节点扩展。该阶段首先生成一组新的候选联合动作，然后调用环境模型推进到下一局势状态，并将新状态作为当前节点的子节点加入搜索树。这样，搜索树中的一条边对应一组连续联合动作，一个子节点对应执行该动作后的后续对抗局势。

**3. 叶节点估值**

当搜索路径触及叶节点后，需要估计该节点之后的长期收益。本文的搜索器支持两种估值方式：一种是继续执行随机滚动仿真，累计后续奖励作为估值结果；另一种是调用训练得到的价值网络，直接对叶节点状态给出近似价值。前者保留了基于环境仿真的真实性，后者能够减少深层随机仿真带来的计算开销。具体的价值网络训练与叶节点辅助估值方法将在后续价值网络部分进一步说明。

**4. 路径回传**

完成叶节点估值后，搜索器沿本轮访问路径进行回传更新。路径上各节点的访问次数增加一次，同时根据本轮得到的折扣回报更新累计价值和平均价值。由于本文任务包含多个智能体，节点价值以向量形式保存，因此回传过程会同时更新各智能体对应的收益估计。

经过多轮模拟后，根节点下的各子节点形成不同候选联合动作的统计结果。每个根节点子节点对应一组候选联合动作，并具有相应的访问次数和平均价值。本文优先选择访问次数最多的根节点子节点作为搜索结果：

$$c^*=\arg\max_{c\in\mathcal{C}_0}N_c,\qquad \mathbf{a}^*=\mathbf{a}_{0\to c^*}. \tag{3-10}$$

其中，$\mathbf{a}_{0\to c^*}$ 表示从根节点转移到最优子节点所对应的联合动作。若访问次数统计无法给出有效分支，则退化为选择当前评价方平均价值最高的子节点。

图 3-6将根节点的高访问搜索分支可视化。四个子图分别表示两个逃逸者和两个追捕者，黑色叉号为根节点位置，颜色表示搜索深度，线宽表示访问次数。图中分支为搜索器模拟得到的候选未来状态转移，并非实际执行轨迹。

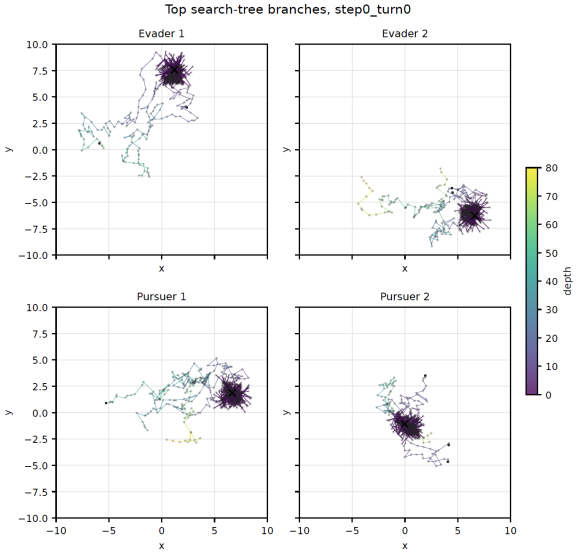



图 3-6 高访问树搜索分支可视化

## 3.3 策略网络

策略网络用于对专家搜索器生成的动作数据进行参数化拟合。前文已经通过 PUCT 搜索器在给定对抗状态下输出质量较高的专家动作，但该过程需要大量前向推演和节点统计，直接用于实时决策会带来较高计算开销。因此算法同时采用两类策略：一类是用于在线部署的快速反应式策略，另一类是能够进行多步规划、但计算开销较高的慢速非反应式策略。对应到本文中，策略网络属于前者，搜索器属于后者。因此可通过行为克隆利用搜索结果训练策略网络，使策略网络学习从环境观测编码到连续动作的映射关系。

这里并未采用直接学习全局联合动作的方式，而是针对每个智能体分别构建独立的策略网络。具体而言，第 $i$ 个智能体的策略网络以其对应的观测编码作为输入，负责映射生成该智能体在连续空间下的动作分量。这种设计将高维的联合动作决策任务解耦为多个局部动作的学习子问题，在有效降低神经网络输出维度的同时，也显著提升了系统对于智能体失效或非激活状态的处理灵活性与鲁棒性。

### 3.3.1 策略训练样本构造

策略网络的训练目标是建立从局部局势观测到专家动作的高维度映射关系。为实现这一目标，需将上一节中搜索器生成的决策统计结果转化为标准的监督学习样本。为保证训练数据能够真实反映机器人在追逃、规避和对抗等博弈阶段的实际分布，算法并未在全局状态空间中进行盲目的均匀抽样，而是从环境初始状态出发，由当前策略或随机策略驱动与环境进行多步交互。设在此时序推进过程中采集到的真实可达状态集合为：

$$\mathcal{S}_{\pi}=\left\{s^{(1)},s^{(2)},\cdots,s^{(N_{\pi})}\right\}. \tag{3-11}$$

这种基于真实轨迹的采样方式，有效保障了训练数据与实际对抗场景状态分布的一致性，避免了脱离环境动力学转移规律的无效探索。

针对集合中的任意采样状态 $s^{(j)}$，搜索器将其作为根节点执行高预算的树搜索模拟。搜索终止后，根节点下各动作分支的访问次数被完整记录，以反映搜索算法对各动作长期收益的综合评估。设根节点子节点集合为 $\mathcal{C}_0^{(j)}$，则与之对应的边动作与访问次数统计集合可表示为：

$$\mathcal{B}^{(j)}=\left\{\left(\mathbf{a}_{0\to c}^{(j)},N_c^{(j)}\right)\mid c\in\mathcal{C}_0^{(j)}\right\}, \tag{3-12}$$

其中，$\mathbf{a}_{0\to c}^{(j)}$ 表示从根节点转移到子节点 $c$ 所执行的完整联合动作。在此基础上，算法选取访问频次最高的分支作为专家主导方向，定义最优分支为：

$$c_j^{*}=\arg\max_{c\in\mathcal{C}_0^{(j)}}N_c^{(j)}, \tag{3-13}$$

由此提取出对应的专家联合动作 $\mathbf{a}^{*(j)}=\mathbf{a}_{0\to c_j^{*}}^{(j)}$。本文策略网络采用去中心化的单智能体架构设计，全局联合动作需根据索引被进一步分解。设 $\mathcal{I}_i$ 为第 $i$ 个智能体在联合动作向量中的索引区间，则该智能体的专属专家动作标签被提取为 $a_i^{*(j)}=\mathbf{a}^{*(j)}[\mathcal{I}_i]$。同时，全局环境状态 $s^{(j)}$ 需经过预设的局部观测编码函数 $\phi_i(\cdot)$ 处理，从中提取出专属于该智能体的状态特征向量 $x_i^{(j)}=\phi_i(s^{(j)})$。通过这一编码机制，完整且复杂的全局对抗状态被转换为策略网络可直接处理的有效输入。综合上述观测编码与动作标签，第 $i$ 个智能体的策略训练数据集最终构建为：

$$\mathcal{D}_{\pi}^{(i)}=\left\{\left(\phi_i(s^{(j)}),\mathbf{a}^{*(j)}[\mathcal{I}_i]\right)\right\}_{j=1}^{N_{\pi}}. \tag{3-14}$$

该构造过程成功将复杂的树搜索联合决策产物转化为多组独立的单智能体监督信号，大幅降低了策略网络局部动作映射的学习难度。

**经验回放**

考虑到多智能体对抗环境具有强烈的非平稳性，且连续动作空间下的优质专家探索样本较为稀疏，为提升历史样本的利用效率并缓解数据更迭带来的训练震荡，新生成的样本集不会直接覆盖旧数据，而是被存入策略样本回放池中。在每次训练迭代前，系统基于时间加权策略从回放池中重新采样构建训练批次。具体而言，设回放池中共容纳 $T$ 轮历史样本，为使网络优先吸收最新的专家经验同时兼顾优质的历史策略，第 $t$ 轮样本的抽样权重被设计为线性递增形式：

$$p_t = \frac{t}{\sum_{\tau=1}^{T} \tau}. \tag{3-15}$$

这种基于时序优先级的加权回放机制，在平滑数据分布突变与加速新知识吸收之间取得了良好平衡。

在进入网络训练前，采样得到的数据批次被进一步划分为训练集与测试集。训练集直接用于驱动网络权重的梯度更新，测试集则用以实时监控动作拟合误差与评估模型的泛化能力。至此，基于 MCTS 的专家先验已全面转化为神经网络可用的监督数据流，为后续的行为克隆训练奠定了坚实数据基础。

### 3.3.2 策略网络的行为克隆训练

完成策略训练样本构造后，策略网络通过行为克隆方法拟合搜索器输出的专家动作。根据 DPI 框架，训练过程中可以同时维护一个用于在线部署的快速反应式策略和一个能够进行多步规划的慢速专家策略；前者通过模仿后者产生的专家决策实现更新。对应到本文中，策略网络作为快速反应式策略，MCTS 搜索器作为慢速专家策略。由于直接使用 MCTS 进行实时决策计算开销较大，因此本文将搜索器输出的专家动作转化为监督学习样本，训练策略网络学习从环境观测编码到连续动作的映射关系。

在网络结构上，本文为每个智能体分别建立独立的策略网络。对于第 $i$ 个智能体，策略网络以其观测编码 $x_i$ 为输入，输出该智能体的连续动作。相比直接拟合完整联合动作，单智能体独立建模能够降低网络输出维度，也便于处理不同智能体的动作边界和失活状态。

策略网络采用多层前馈神经网络结构，并保留高斯策略输出接口。网络首先输出动作均值和标准差参数。在行为克隆训练阶段，主要约束网络输出的均值动作，使其尽可能接近专家动作标签。由于连续动作需要满足环境中的动作边界约束，网络输出需经过限幅映射。设第 $i$ 个智能体的动作下界和上界分别为 $a_i^{\min}$ 和 $a_i^{\max}$，则动作输出为

$$\hat{a}_i = \frac{a_i^{\max} + a_i^{\min}}{2} + \frac{a_i^{\max} - a_i^{\min}}{2} \tanh\left(\mu_{\theta_i}(x_i)\right). \tag{3-16}$$

其中，$\mu_{\theta_i}(x_i)$ 为策略网络输出的动作均值。该映射先通过 $\tanh(\cdot)$ 将网络输出压缩到 $[-1,1]$ 区间，再映射到环境允许的动作范围内，从而保证输出动作满足物理约束。

设第 $i$ 个智能体的训练样本由观测编码和专家动作标签组成，其中 $a_i^{*(j)}$ 表示第 $j$ 个样本对应的专家动作，$\hat{a}_i^{(j)}$ 表示策略网络的预测动作。本文采用均方误差作为行为克隆损失：

$$\mathcal{L}_{\pi}^{(i)}(\theta_i) = \frac{1}{N_{\pi} D_i} \sum_{j=1}^{N_{\pi}} \sum_{d=1}^{D_i} \left(\hat{a}_{i,d}^{(j)} - a_{i,d}^{*(j)}\right)^2. \tag{3-17}$$

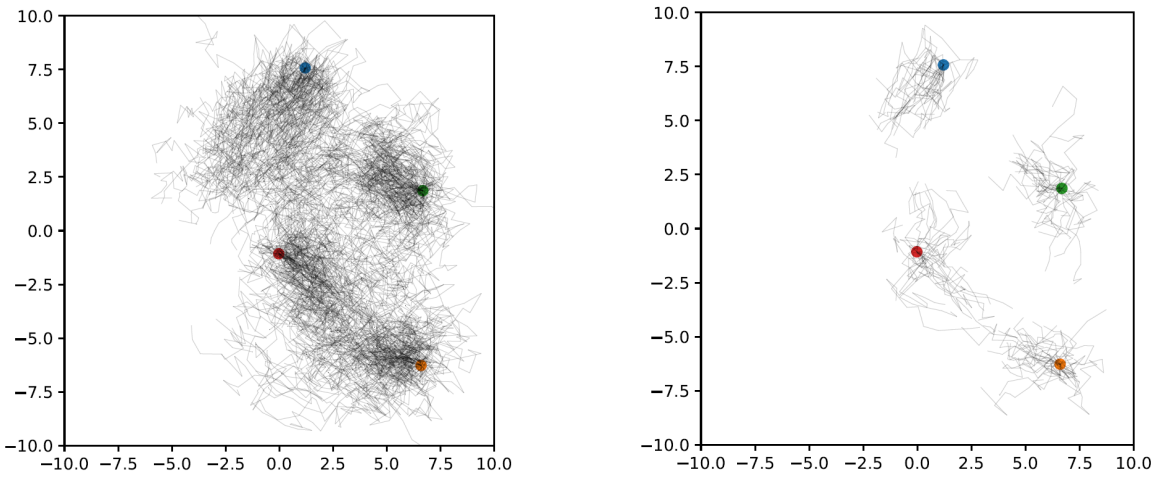
其中，$N_{\pi}$ 为训练样本数量，$D_i$ 为第 $i$ 个智能体的动作维度。通过最小化预测动作与专家动作之间的误差，策略网络能够学习专家搜索器在不同局势下的动作选择规律。

在实际训练过程中，样本集被划分为训练集和测试集。训练集用于小批量梯度更新，测试集用于监控模型的拟合效果和泛化能力。本文采用 AdamW 优化器更新网络参数，并保存测试集损失较低时对应的模型参数，作为后续在线决策和搜索引导使用的策略网络。

训练后的策略网络在系统中主要承担两方面作用：一是作为轻量化策略直接输出连续动作，二是在搜索过程中提供候选动作参考。图 3-7 给出了专家搜索器与训练后策略网络在相同场景下的轨迹分布对比。可以看出，学习者策略能够在一定程度上复现专家搜索器的动作分布特征，说明策略网络能够吸收搜索器生成的专家动作信息。

## 3.4 价值网络

价值网络用于对给定对抗状态的长期回报进行快速估计。相比策略网络直接输出连续动作，价值网络不参与动作生成，而是在树搜索过程中为叶节点提供状态价值评估，从而减少深度随机滚动仿真带来的极高计算开销。




（a）专家策略轨迹分布 (小参数示意图)　　（b）学习者策略轨迹分布 (小参数示意图)

图 3-7 专家搜索器与神经网络策略轨迹分布对比

### 3.4.1 价值样本构造与网络训练

价值网络的训练目标是根据当前对抗状态估计后续长期回报。与策略网络不同，价值网络不直接输出动作，而是为搜索过程提供状态价值评估。因此，其训练样本由状态编码及其对应的长期回报标签组成。

在样本采集过程中，算法首先从当前策略与环境交互产生的真实可达状态中进行采样。对于每一个采样状态，系统将其作为仿真起点，调用当前阶段的策略网络继续驱动环境演化，直到回合结束或达到最大仿真步数。由此可以得到从该状态出发的一段后续对抗过程，并记录其中每一步的即时奖励。为减小不同奖励项量级差异对训练的影响，本文对即时奖励进行归一化处理，并将归一化后的折扣累计回报作为价值网络的监督标签：

$$\mathbf{v}^{*(j)} = \sum_{t=0}^{T_j-1} \gamma^t \mathbf{r}_t^{\mathrm{norm},(j)}. \tag{3-18}$$

其中，$T_j$ 表示从采样状态 $s^{(j)}$ 出发后的实际仿真长度，$\gamma$ 为折扣因子，$\mathbf{r}_t^{\mathrm{norm},(j)}$ 为第 $t$ 步归一化后的即时奖励向量。该标签反映了在当前策略作用下，各智能体从状态 $s^{(j)}$ 出发能够获得的长期收益估计。

在输入构造上，原始环境状态先经过状态编码函数 $\psi(\cdot)$ 转换为网络输入特征。价值网络以该状态特征为输入，同时输出所有智能体的回报估计。设价值网络对第 $j$ 个样本的预测结果为 $\hat{\mathbf{v}}^{(j)} = V_\eta(\psi(s^{(j)}))$，其中 $\eta$ 为网络参数。训练时采用元素级均方

误差作为损失函数：

$$\mathcal{L}_V(\eta) = \frac{1}{N_V N_r} \sum_{j=1}^{N_V} \sum_{i=1}^{N_r} \left( \hat{v}_i^{(j)} - v_i^{*(j)} \right)^2 . \tag{3-19}$$

其中，$N_V$ 为价值样本数量，$N_r$ 为智能体数量。通过最小化预测回报与监督标签之间的误差，价值网络能够学习对不同对抗状态的长期收益进行近似评估。

在样本管理方面，价值网络沿用与策略网络相同的经验回放机制。新生成的价值样本被加入回放池，并在训练时按照时间权重进行采样，使网络在优先学习近期样本的同时保留部分历史样本。该机制有助于缓解样本分布变化带来的训练波动，提高价值网络训练过程的稳定性。

### 3.4.2 搜索过程中的价值估计

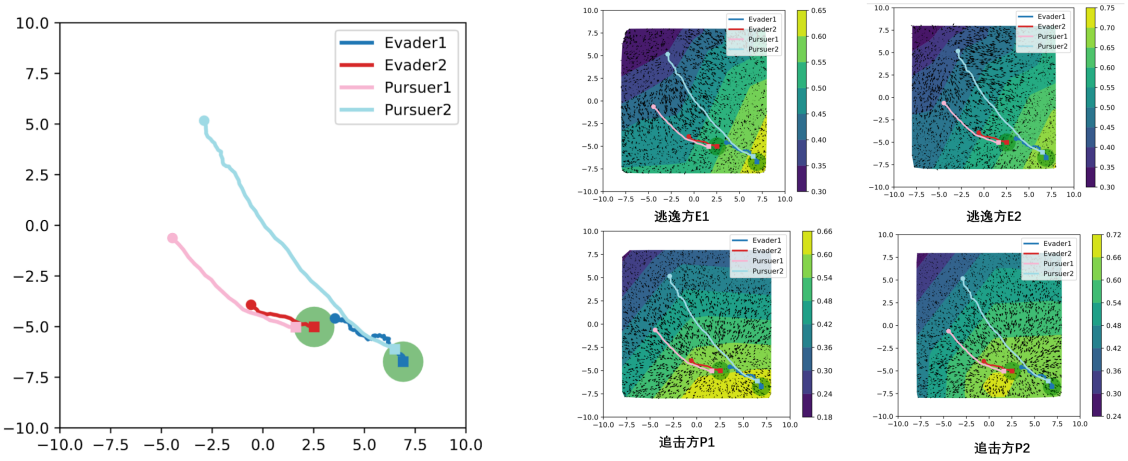
价值网络训练完成后，将被在线部署于树搜索的叶节点估值环节。如前文 3.2.2 节所述，在一次完整的 MCTS 迭代中，当搜索路径触及最大深度或末端状态 $s_L$ 时，系统必须对其后续长期收益进行精确评估。若完全依赖深层的随机仿真，计算开销将随搜索规模呈指数级增长，难以满足多机器人高频对抗的实时性要求。价值网络的引入，正是为了对末端状态给出快速的回报估计，从而大幅削减搜索树的拓展成本。

在算法的在线推演中，系统首先提取末端状态的环境特征 $z_L = \psi(s_L)$ 并输入至价值网络，直接获取多智能体回报估计向量 $\hat{\mathbf{v}}_L = V_\eta(z_L)$。需要指出的是，为了保证搜索算法在复杂环境下的鲁棒性，算法在底层评价函数中引入了受控于参数 $\beta_{\text{value}}$ 的混合估值机制：在每次叶节点评估时，系统以 $\beta_{\text{value}}$ 的概率调用价值网络给出先验估值，而以 $1-\beta_{\text{value}}$ 的概率退化为常规的随机仿真以累计真实奖励。这种软替代机制确保了在价值网络尚未加载完全或估值出现偏差时，搜索树仍能借助真实动力学推演进行基本的决策。

获取到末端估值 $\hat{\mathbf{v}}_L$ 后，该估计量将沿着本轮的访问路径进行折扣累加与回传，同步更新沿途各节点的累计价值与平均价值分量。价值网络输出并不直接指定动作，而是将其先验判断潜移默化地融入上置信界（UCB）准则的价值项 $Q_c^{(\rho_n)}$ 中。随着模拟迭代的增加，网络提供的平滑估值会显著改变搜索器对不同动作分支的访问倾向，使有限的搜索算力能够快速向具备高长期回报潜力的战术分支集中。

价值网络与 MCTS 之间形成了一种深刻的优势互补关系：价值网络以较低的计

算开销提供了近似的收益预判，提高了搜索效率；而树搜索则保留了渐进扩展与探索项机制。通过两者的结合，系统既避免了单一网络估值误差导致搜索过早陷入局部最优，又利用多次模拟统计修正了单次估值的不确定性，较好地满足了在线对抗决策的实际需求。




(a) 平面运动轨迹　　(b) 四个机器人在初始位置时的价值热力图

图 3-8 价值网络示意图

## 3.5 本章小结

本章围绕多智能体连续动作对抗任务中的实时决策难题，提出了一种基于搜索引导与模仿学习相结合的策略生成框架，通过引入神经网络实现了离线专家知识的有效压缩与在线轻量化部署。本章详细阐述了该框架下三大核心模块的闭环协作机制：利用基于 PUCT 的搜索器在多智能体联合动作空间中生成高质量专家决策样本；采用去中心化策略网络通过行为克隆精准拟合专家动作分布，以提供在线先验引导；引入价值网络评估长时折扣回报实现叶节点快速估值，从而大幅降低深层随机仿真的算力依赖。该设计有效平衡了决策质量与实时性，为后续章节在具体仿真环境中的实验验证与性能分析奠定了扎实的理论与方法基础。

# 第 4 章 面向全局感知的 2v2 追逃对抗场景建模与实验验证

第三章给出了搜索器、策略网络和价值网络组成的对抗策略生成方法。为验证该方法在连续动作追逃任务中的有效性，本章构建全局感知条件下的 2v2 追逃对抗场景，并开展仿真实验。在本章设定中，智能体能够直接获取完整全局状态，场景中暂不考虑局部感知、障碍物遮挡和底层轨迹规划约束，从而将实验重点集中于搜索–学习融合方法本身的决策性能。局部感知和部署约束将在第五章进一步讨论。

## 4.1 追逃对抗场景描述

本章研究二维连续无障碍平面内的 2v2 多智能体追逃对抗问题。场景中包含两名逃逸方智能体和两名追捕方智能体，双方在同一有界区域内进行有限时域对抗。追捕方目标是在规定时间内完成对逃逸方成员的捕获，逃逸方目标是在追捕压力下尽可能延长团队存活时间。

系统采用基于相对距离的捕获规则。当某一追捕者与某一逃逸者之间的欧氏距离小于捕获阈值时，判定该追逃对形成有效捕获。为简化多机器人交互关系，本文采用一对一兑子机制，即形成捕获的追捕者和逃逸者同时失活，并不再参与后续决策。对抗过程持续至逃逸方全部失活、达到最大对抗时间或发生越界事件。为避免初始状态直接触发捕获，每局开始时还要求任意跨阵营智能体之间满足最小安全间距约束。

## 4.2 全局感知条件下的任务建模

在全局感知设定下，系统能够直接获取四个智能体的位置、存活状态和当前对抗时间。与局部感知场景不同，全局感知下的系统不考虑传感器视野、遮挡关系和观测噪声，而是将完整系统状态作为策略网络、价值网络和树搜索器的输入。该设定用于剥离感知层面的不确定因素，使实验重点集中于搜索–学习融合方法本身的决策性能。

### 4.2.1 状态空间与动作空间

设逃逸方智能体为 $E_1, E_2$，追捕方智能体为 $P_1, P_2$。在离散决策时刻 $k$，智能体 $i$ 的二维位置记为 $\mathbf{p}_{i,k} \in \mathbb{R}^2$，存活状态记为 $z_{i,k} \in \{0, 1\}$。当 $z_{i,k} = 1$ 时，智能体仍参

与对抗；当 $z_{i,k}=0$ 时，智能体已失活。

系统状态由四个智能体的位置、当前时间和存活状态组成：

$$\begin{aligned} s_k = [&\mathbf{p}_{E_1,k}^T, \mathbf{p}_{E_2,k}^T, \mathbf{p}_{P_1,k}^T, \mathbf{p}_{P_2,k}^T, t_k, \\ &z_{E_1,k}, z_{E_2,k}, z_{P_1,k}, z_{P_2,k}]^T \in \mathbb{R}^{13}. \end{aligned} \tag{4-1}$$

其中，前 8 维为四个智能体的平面位置，第 9 维为当前对抗时间，最后 4 维为各智能体的存活状态。有效对抗区域记为 $\Omega$，智能体位置需满足 $\mathbf{p}_{i,k}\in\Omega$，当前时间满足 $t_k\in[0,T]$。

动作空间采用二维连续相对位移形式。智能体 $i$ 在时刻 $k$ 的动作定义为

$$a_{i,k} = \Delta\mathbf{p}_{i,k} = [\Delta x_{i,k}, \Delta y_{i,k}]^T \in \mathbb{R}^2. \tag{4-2}$$

该动作表示当前决策周期内相对于当前位置的目标位移。设智能体速度上限为 $v_i^{\max}$，时间步长为 $\Delta t$，则单步动作满足

$$\|a_{i,k}\|_\infty \le v_i^{\max}\Delta t. \tag{4-3}$$

四个智能体的动作共同构成系统联合动作：

$$\mathbf{a}_k = [a_{E_1,k}^T, a_{E_2,k}^T, a_{P_1,k}^T, a_{P_2,k}^T]^T \in \mathbb{R}^8. \tag{4-4}$$

当某一智能体已经失活时，其动作分量在状态推进中被视为无效输入，并保持原位置不变。由于联合动作属于连续高维空间，搜索器无法穷举全部动作，因此后续实验采用渐进扩展和策略网络先验辅助连续动作搜索。

### 4.2.2 状态转移与约束条件

设时间步长为 $\Delta t$，在给定当前状态 $s_k$ 和联合动作 $\mathbf{a}_k$ 后，环境按照离散时间模型推进：

$$s_{k+1} = F(s_k, \mathbf{a}_k), \tag{4-5}$$

其中，$F(\cdot)$ 表示追逃环境的状态转移函数。具体而言，状态转移过程包括位置更新、捕获结算和边界检查三个步骤。

首先，对于仍处于活动状态的智能体，其位置按照单步相对位移更新：

$$\mathbf{p}_{i,k+1} = \begin{cases} \mathbf{p}_{i,k} + \mathrm{clip}\left(a_{i,k}, -v_i^{\max}\Delta t, v_i^{\max}\Delta t\right), & z_{i,k} = 1, \\ \mathbf{p}_{i,k}, & z_{i,k} = 0. \end{cases} \tag{4-6}$$

其中，clip$(\cdot)$ 表示逐维限幅操作。系统时间按照 $t_{k+1} = t_k + \Delta t$ 更新。

位置更新后，系统根据追捕方与逃逸方之间的距离进行捕获判定。若存活追捕者 $P_i$ 与存活逃逸者 $E_j$ 满足

$$\left\|\mathbf{p}_{P_i,k+1} - \mathbf{p}_{E_j,k+1}\right\|_2 \le d_c, \tag{4-7}$$

则触发捕获事件，其中 $d_c$ 为捕获距离阈值。若同一时刻存在多个满足捕获条件的追逃对，系统按距离由近到远进行一对一匹配，并将匹配成功的追捕者和逃逸者同时置为失活。

与此同时，系统要求所有活动智能体保持在有效区域 $\Omega$ 内。若任一智能体越界，则当前回合提前终止。上述机制共同构成了本章全局感知环境的状态转移规则。

### 4.2.3 奖励函数与终止判定

奖励函数用于刻画追捕方尽早捕获和逃逸方延长存活时间之间的对抗目标。记状态 $s_k$ 下仍处于活动状态的逃逸方数量为

$$N_E(s_k) = \sum_{i\in\mathcal{E}} z_{i,k}, \tag{4-8}$$

其中，$\mathcal{E} = \{E_1, E_2\}$ 表示逃逸方集合。单步转移中新失活的逃逸方数量为

$$c_k = N_E(s_k) - N_E(s_{k+1}). \tag{4-9}$$

当 $c_k > 0$ 时，说明该步发生有效捕获。设最大对抗时长为 $T$，则捕获奖励、存活奖励和越界惩罚定义为

$$
\begin{aligned}
r_{P,k}^{\text{cap}} &= \frac{1}{2} c_k \left(1 - \frac{t_{k+1}}{T}\right), \\
r_{E,k}^{\text{cap}} &= \frac{1}{2} c_k \frac{t_{k+1}}{T}, \\
r_{E,k}^{\text{sur}} &= \frac{1}{2} N_E(s_{k+1}) \mathbb{I}[t_{k+1} \geq T], \\
r_{i,k}^{\text{out}} &= \begin{cases} -1, & \mathbf{p}_{i,k+1} \notin \Omega, \\ 0, & \mathbf{p}_{i,k+1} \in \Omega. \end{cases}
\end{aligned}
\tag{4-10}
$$

其中，$r_{P,k}^{\text{cap}}$ 和 $r_{E,k}^{\text{cap}}$ 分别表示追捕方和逃逸方在捕获事件中的团队奖励。捕获越早，追捕方奖励越高；捕获越晚，逃逸方获得的时间收益越高。

对于逃逸方成员 $i \in \mathcal{E}$ 和追捕方成员 $j \in \mathcal{P}$，其中 $\mathcal{P} = \{P_1, P_2\}$ 表示追捕方集合，其单步奖励分别为

$$
r_{i,k} = r_{E,k}^{\text{cap}} + r_{E,k}^{\text{sur}} + r_{i,k}^{\text{out}}, \qquad r_{j,k} = r_{P,k}^{\text{cap}} + r_{j,k}^{\text{out}}. \tag{4-11}
$$

单局对抗在以下任一条件满足时终止：逃逸方全部失活、达到最大对抗时间，或存在智能体越界。终止条件可写为

$$
\text{Terminal}(s_{k+1}) = \mathbb{I}\left[N_E(s_{k+1}) = 0 \ \vee \ t_{k+1} \geq T \ \vee \ \exists i, \ \mathbf{p}_{i,k+1} \notin \Omega\right]. \tag{4-12}
$$

上述奖励与终止机制为后续搜索评估和策略学习提供统一的环境反馈。后续实验主要从对抗效果、捕获效率、收益质量和在线计算开销四个方面评价策略性能。对抗效果主要由总捕获率、双目标捕获率和平均捕获数反映，用于衡量追捕方完成捕获任务的程度；捕获效率由平均捕获时间反映，用于衡量追捕方完成捕获的快慢或逃逸方延缓捕获的能力；收益质量由团队回报反映，用于综合评价策略在奖励函数下的长期表现；在线计算开销由单步决策耗时反映，用于衡量策略部署时的实时性。不同实验中指标的优劣方向与被评价对象有关，并在结果表格中通过 $\uparrow$ 和 $\downarrow$ 标注。

## 4.3 实验环境与参数设置

实验依托高性能计算节点开展，硬件搭载双路 Intel Xeon Gold 6330 处理器（112 线程）与 4 张 NVIDIA GeForce RTX 4090 显卡（单卡 24 GB 显存）。算法逻辑基于

Python 3.11 开发，深度学习模块基于 PyTorch 2.1.0 构建，并利用 CUDA 12.8 实现模型训练与在线推演的 GPU 并行加速。

系统构建的对抗环境为二维无障碍连续平面。环境的状态转移与捕获判定严格按照动力学与距离阈值进行，具体的场景规模与环境参数配置如表 4-1 所示。

在算法运行层面，离线训练阶段通过 PUCT 搜索器生成高质量专家样本，并利用经验回放池实现样本的加权复用，指导高斯策略网络与价值网络的参数更新；在线测试阶段则利用训练后的网络辅助搜索。核心的训练与搜索超参数如表 4-2 所示

表 4-1 全局感知追逃对抗环境参数

| 参数名称 | 取值 |
|---|---|
| 对抗区域 $\Omega$ | $[-10,10]\times[-10,10]$ |
| 初始采样区域 | $[-8,8]\times[-8,8]$ |
| 初始两队最小间距阈值 | 4.0 |
| 最大对抗步数 $T$ | 80 |
| 时间步长 $\Delta t$ | 1 |
| 捕获距离阈值 $d_c$ | 1.0 |
| 速度上限 | 1.0 |
| 折扣因子 $\gamma$ | 1.0 |

## 4.4 实验结果与分析

### 4.4.1 离线训练结果分析

为验证策略网络和价值网络训练过程的稳定性，图 4-1 给出了不同外层学习迭代轮次下的网络损失变化曲线。其中，第一行和第二行分别对应智能体 0 与智能体 2 的策略网络训练损失，第三行对应价值网络训练损失；三列分别表示外层学习迭代轮次为 $l=0$、$l=7$ 和 $l=30$ 时的训练过程。

可以看出，随着训练轮数增加，策略网络和价值网络的损失整体呈下降趋势，并逐渐趋于稳定。

特别地，对比不同外层学习迭代轮次下的损失曲线可以看出，在初期（$l=0$）和后期（$l=30$）阶段，训练集与测试集的损失曲线贴合较为紧密；而在中期（$l=7$）

表 4-2 训练与搜索超参数设置

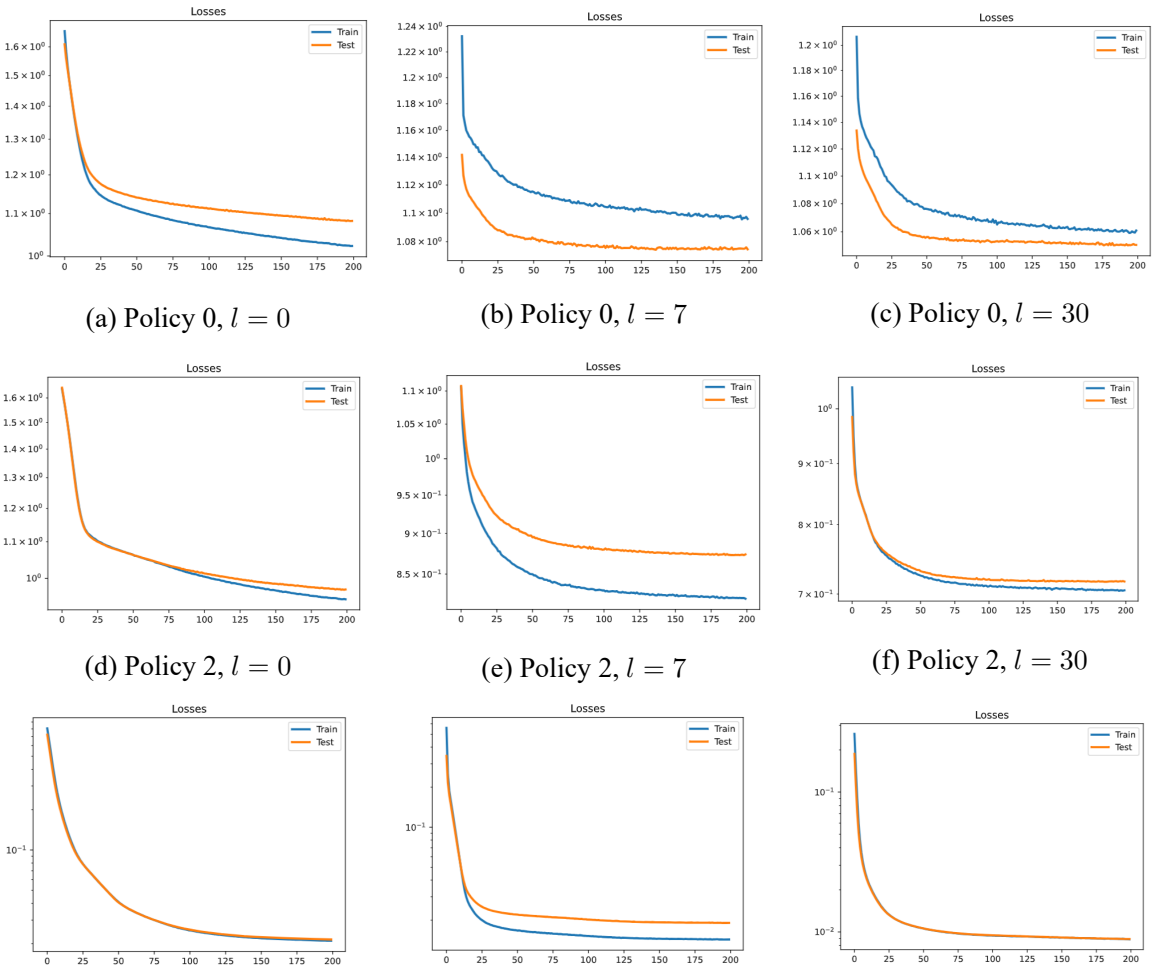
| 参数名称 | 取值 |
|---|---|
| 外层学习迭代轮数 $L$ | 80 |
| 单轮策略/价值样本规模 $\lvert\mathcal{D}_\pi\rvert = \lvert\mathcal{D}_v\rvert$ | 20000 |
| 训练阶段搜索模拟次数 | 3000 |
| 训练阶段最大搜索深度 | 200 |
| 部署阶段搜索模拟次数 | 1000 |
| 部署阶段最大搜索深度 | 100 |
| 渐进扩展参数 $(C_{\text{pw}}, \alpha_{\text{pw}})$ | $(2.0,\ 0.5)$ |
| 探索项参数 $(C_{\text{exp}}, \alpha_{\text{exp}})$ | $(1.0,\ 0.25)$ |
| 训练阶段网络融合系数 $(\beta_\pi, \beta_v)$ | $(0.5,\ 0.5)$ |
| 优化器 | AdamW |
| 学习率 (Learning Rate) | $7 \times 10^{-4}$ |
| 训练批大小 (Batch Size) | 4096 |
| 训练轮数 (Epoch) | 200 |
| 训练-测试集划分比例 | 0.8 |
| 经验回放容量倍率 | 20 |

阶段，两组曲线存在相对明显的间距。这一现象深入反映了双策略自博弈迭代过程中的非平稳性特征：在初期，智能体策略尚未演化，交互探索出的局势状态空间相对简单，训练与测试数据损失均偏高；在中期，双方策略快速演化并涌现出多样化对抗战术，使得训练集与测试集在分布上存在短期差异；而在后期，双方攻防策略博弈逐渐趋于相对稳定，损失曲线再次贴合。

该结果说明，策略网络能够从搜索生成的专家动作样本中学习到较稳定的状态–动作映射关系，价值网络也能够对搜索和仿真过程中得到的长期回报形成有效拟合。由此可见，搜索生成的专家样本能够为后续策略蒸馏和价值估计提供有效监督信号。

### 4.4.2 典型对抗轨迹分析

为直观分析全局感知条件下 2v2 追逃对抗过程中的策略行为，本节选取测试过程中的两组典型对抗轨迹进行说明。这两组轨迹分别对应了双目标成功捕获和逃逸方存活两类极具代表性的博弈结果。轨迹图中，实心圆点表示各智能体初始位置，方块表示终止位置，绿色圆形区域标识了最终捕获发生时的有效判定范围。详细状态




(a) Policy 0, $l = 0$　(b) Policy 0, $l = 7$　(c) Policy 0, $l = 30$

(d) Policy 2, $l = 0$　(e) Policy 2, $l = 7$　(f) Policy 2, $l = 30$

(g) Value, $l = 0$　(h) Value, $l = 7$　(i) Value, $l = 30$

图 4-1 策略网络与价值网络训练损失变化

图同步给出了各智能体的位置分量、动作幅值、追逃最小距离以及团队累计奖励随时间演化的完整过程。

图 4-3 展示了追捕方获胜的过程。从平面轨迹 (a) 中可以清晰地观察到融合算法涌现出了较高水平的集中优势兵力与协同转火战术。

结合细节图 4-3(b) 的时间线还原其博弈全貌：在对抗伊始，位于左下角的粉色追捕者（Pursuer 1）并未就近追击右侧的红色逃逸者（Evader 2），而是选择向右上方前进，与浅蓝色追捕者（Pursuer 2）一起，优先对深蓝色逃逸者（Evader 1）发起了局部 2v1 的追击。在 $t \approx 6$ 附近，浅蓝方成功将深蓝方捕获，首次兑子完成。在深蓝方失活后，赶到中场的粉色追捕者迅速完成目标切换，向右下方长驱直入追击红色逃逸者。在残局博弈中，红色逃逸者在右下角进行了一次大范围的迂回机动并试

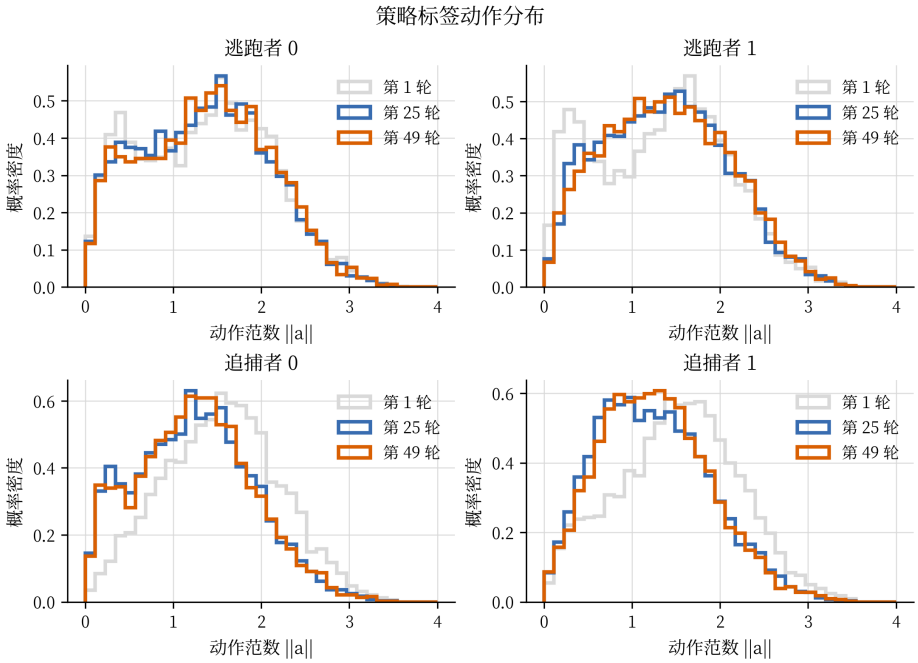
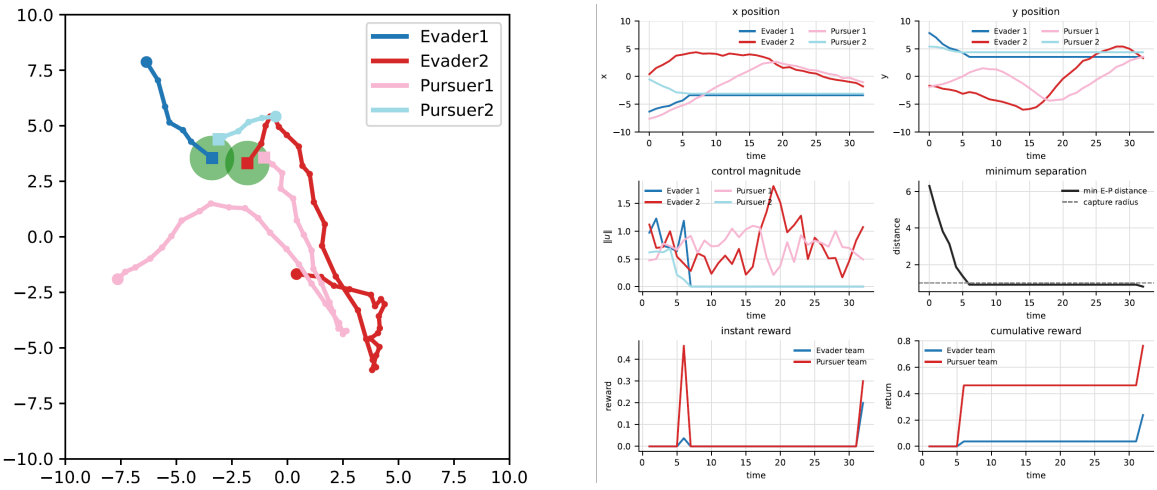



图 4-2 不同训练轮次下各智能体专家动作标签范数分布。各智能体动作标签主要集中在有限范围内，且中后期分布形态趋于稳定，说明搜索器生成的专家动作样本具有较稳定的尺度特征



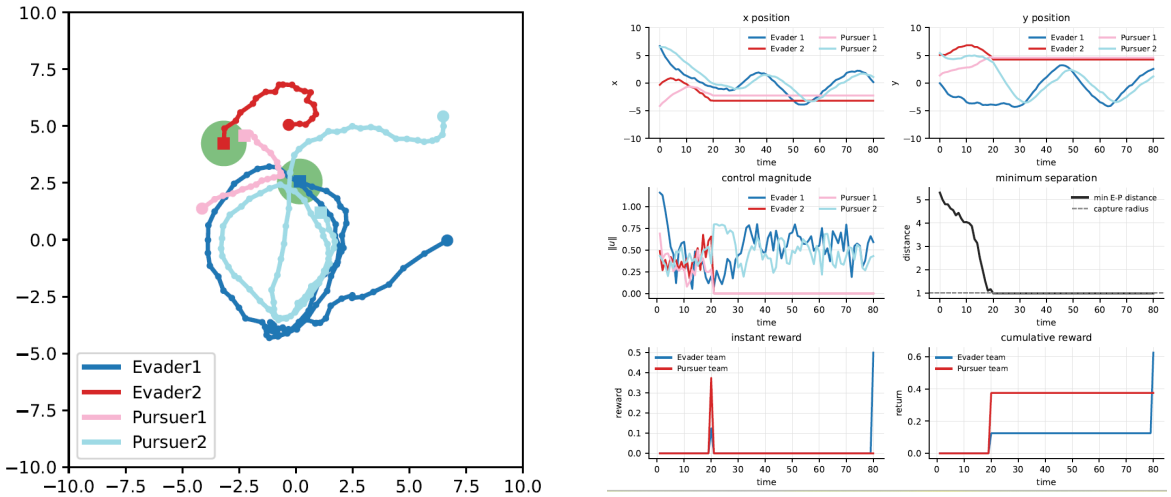

(a) 平面运动轨迹

(b) 状态、动作与奖励变化

图 4-3 双目标成功捕获的典型对抗轨迹

图向场地左上方逃窜。面对此情形，粉色追捕者并未陷入盲目的尾随追击，而是敏锐地预判了其逃逸路线，直接采取直线插断策略，成功截断了红方的突围路线，于 $t \approx 33$ 附近完成第二次成功捕获。

从奖励变化曲线来看，追捕方团队在两次捕获节点均获得了显著的即时正向跃升；而逃逸方则因其在被捕获前的短暂周旋获得了相应的时间收益。同时也可以看出，搜索引导的策略网络并未陷入贪婪的局部最优，而是可以通过多机协同优先建立局部兵力优势以确保首杀，并在残局中利用空间预判完成精准封堵，展现了多步全局规划能力。



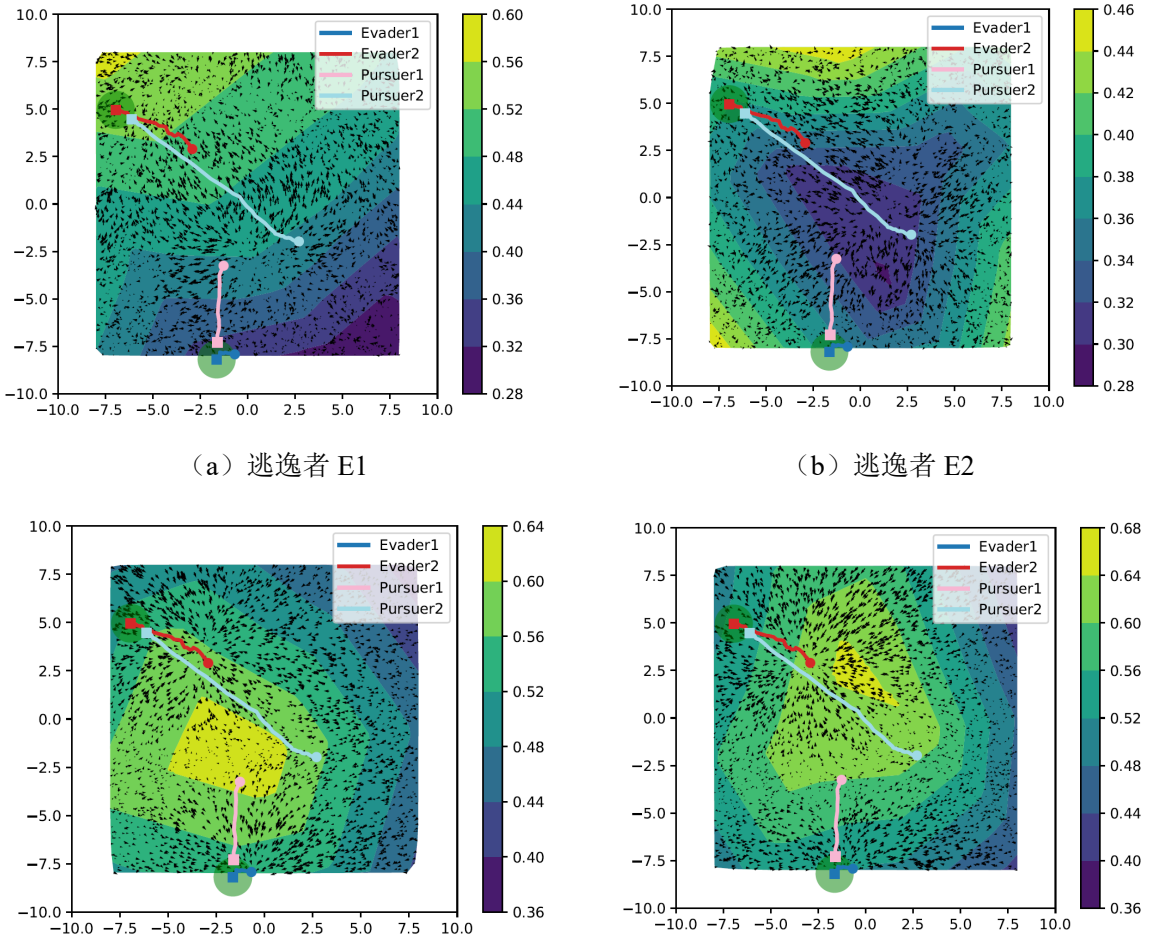

（a）平面运动轨迹　　（b）状态、动作与奖励变化

图 4-4 一换一兑子后逃逸方极限存活的典型对抗轨迹

图 4-4 则展示了另一类对抗结果。在该对局中，逃逸方展现出了较高的求生智慧，成功将战局拖延至最大对抗步数。由平面轨迹可见，在 $t \approx 20$ 时，左上方区域发生首次捕捉，此时，剩余的逃逸者并未选择盲目地冲向场地边缘，而是采取了局部周旋战术：在首次捕获后长达 60 步的时间内，追逃双方长期在捕获边缘试探与拉扯，但追捕方始终未能完成实质性的捕获。这说明逃逸方策略学会了利用周旋战术来破坏追捕方的提前量预判。

这两组典型轨迹直观地体现了融合算法在攻防两端的策略。前者验证了多智能体协同拦截与残局连续博弈的连贯性；后者则揭示了逃逸方在劣势下的时空规避与周旋能力。这为后续定量对比实验中引入多维评价指标提供了充分的直观依据与理

论铺垫。




（a）逃逸者 E1　　（b）逃逸者 E2

（c）追捕者 P1　　（d）追捕者 P2

图 4-5 策略网络与价值网络输出的空间分布可视化

上述典型对抗轨迹的形成，本质上源于神经网络对连续对抗态势的深刻理解。图 4-5 进一步提取了决策网络在一个更清晰的对抗过程中的空间分布输出。背景等高线颜色表征了价值网络对局势的实时评估，颜色越亮代表期望收益越高，黑色矢量箭头则代表策略网络的动作先验引导。

如图 4-5(a) 与 (b) 所示，在逃逸过程中，逃逸方网络构建的价值场在追捕者来袭方向呈现明显的低价值分布，其策略场引导机器人始终向高价值的开阔区域周旋；而在图 4-5(c) 与 (d) 的追捕态势中，策略场表现出极强的目标汇聚特性。这组可视化结果不仅印证了前述典型轨迹的合理性，更直观展示了算法在复杂对抗场景下对空间

优势的捕获能力，证明了离线策略蒸馏框架的有效性。

### 4.4.3 不同决策方法对比

为进一步定量评价不同决策方法在全局感知 2v2 追逃对抗任务中的表现，本节选取随机策略、纯策略网络、纯搜索策略以及搜索 + 学习融合策略进行交叉对比测试。不同策略的具体含义如表 4-3 所示。其中，Random 作为基础对照组；Policy Only 用于评估策略网络在不依赖搜索时的决策能力；Search Only 用于评估纯 PUCT 算法的搜索上限；Search + Learning 则是完整融合算法。

表 4-3 不同决策策略类型说明

| 策略名称 | 含义说明 |
|---|---|
| Random | 在连续动作空间内随机采样动作，不引入搜索与神经网络 |
| Policy Only | 仅利用蒸馏后的策略网络进行前向推理，直接输出动作 |
| Search Only | 仅依赖 MCTS 在线搜索，不使用策略网络与价值网络辅助 |
| Search + Learning | 引入策略网络提供动作先验，并结合价值网络评估叶节点，辅助 PUCT 搜索，搜索阶段策略网络和价值网络融合系数均为 0.5 |

测试阶段设置了两类初始位置区域：紧凑区域 $[-4,4]\times[-4,4]$ 和宽域区域 $[-8,8]\times[-8,8]$。前者用于考察近距离快速对抗，后者用于考察长距离环境下的策略稳定性。每组实验独立测试 200 局，主要统计总捕获率、双目标捕获率、平均捕获数、平均捕获时间、追捕方团队回报以及平均单步决策耗时等指标。

**1. 固定追捕方评估逃逸表现**

首先固定追捕方为 Policy Only 策略，比较不同逃逸方策略下的对抗结果，如表 4-4 所示。该实验中追捕方策略保持不变，因此捕获时间、捕获数量和追捕方回报的变化主要反映逃逸方策略对追捕难度的影响。

由表 4-4 和图 4-6 可以看出，在紧凑初始区域 $[-4,4]^2$ 下，Search + Learning 逃逸方对应的平均捕获时间为 16.04 步，高于 Random 策略的 10.34 步、Policy Only 策略的 13.34 步以及 Search Only 策略的 11.08 步；同时，其追捕方团队回报为 1.357，低于其他三类逃逸策略。这说明搜索学习融合逃逸策略能够通过更有效的规避动作延缓捕获过程，并降低追捕方累积收益。在宽域初始区域 $[-8,8]^2$ 下，该趋势更加明

表 4-4 固定追捕方为 Policy Only 时不同逃逸方策略的对抗结果

| 初始区域 | 逃逸方策略 | 总捕获率 (%)↓ | 双目标捕获率 (%)↓ | 平均捕获数↓ | 平均捕获时间 (步)↑ | 追捕方团队回报↓ | 逃逸方单步耗时 (ms)↓ |
|---|---|---|---|---|---|---|---|
| $[-4,4]^2$ | Random | **99** | 95 | 1.94 | 10.34 | 1.582 | **0.06** |
| $[-4,4]^2$ | Policy Only | 100 | 99 | 1.99 | 13.34 | 1.482 | 0.29 |
| $[-4,4]^2$ | Search + Learning | 100 | 96 | 1.96 | **16.04** | **1.357** | 339.89 |
| $[-4,4]^2$ | Search Only | 100 | **88** | **1.88** | 11.08 | 1.423 | 928.76 |
| $[-8,8]^2$ | Random | 75 | 66 | 1.41 | 12.67 | 1.104 | **0.06** |
| $[-8,8]^2$ | Policy Only | **100** | 100 | 2.00 | 15.61 | 1.404 | 0.24 |
| $[-8,8]^2$ | Search + Learning | **100** | 89 | 1.89 | **21.02** | **1.092** | 364.67 |
| $[-8,8]^2$ | Search Only | **100** | **85** | **1.85** | 13.13 | 1.304 | 801.52 |

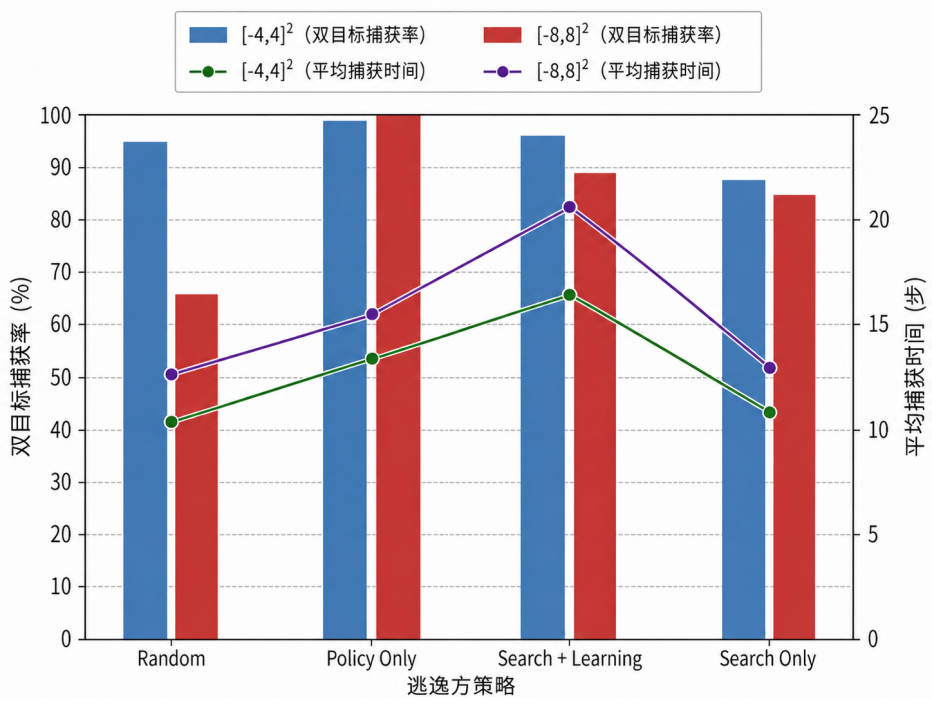



图 4-6 固定追捕方为 Policy Only 时不同逃逸方策略的综合性能对比

显，Search + Learning 逃逸方的平均捕获时间达到 21.02 步，明显高于 Random 策略的 12.67 步、Policy Only 策略的 15.61 步和 Search Only 策略的 13.13 步，同时追捕方团队回报降低至 1.092，表明该策略在初始态势更加分散的情况下仍能保持较强的持续规避能力。

需要注意的是，Random 逃逸方在宽域初始区域下表现出较低的捕获率，但结合实验过程可知，该现象主要与随机动作导致的较高出界率有关。随机策略缺乏对边界约束、追捕方位置和逃逸目标的有效建模，容易使逃逸智能体偏离有效对抗区域，从而影响捕获率和平均捕获数等统计指标的解释，其结果并不能说明随机逃逸具备有效的主动规避能力，而更适合作为最低性能基线。

比较 Search Only 与 Search + Learning 可以发现，Search Only 逃逸方在降低双目标捕获率和平均捕获数方面具有一定优势。在 $[-4,4]^2$ 区域下，Search Only 的双目标捕获率和平均捕获数分别为 88% 和 1.88，低于 Search + Learning 的 96% 和 1.96；在 $[-8,8]^2$ 区域下，Search Only 的双目标捕获率和平均捕获数分别为 85% 和 1.85，也略低于 Search + Learning 的 89% 和 1.89。这说明纯搜索逃逸策略在部分对局中能够降低完全捕获比例。然而，Search Only 的平均捕获时间明显短于 Search + Learning，且对应的追捕方团队回报更高，说明其规避过程的稳定性不足。

从计算开销来看，Search + Learning 逃逸方的单步决策耗时分别为 339.89 ms 和 364.67 ms，明显低于 Search Only 的 928.76 ms 和 801.52 ms。该结果表明，在当前有限搜索预算和连续动作采样条件下，仅依赖纯搜索会带来较大的在线计算负担，而引入策略网络先验和价值网络评估后，搜索过程能够更加集中于高价值动作区域，从而在降低计算耗时的同时延长逃逸方存活时间。

**2. 固定逃逸方评估追捕表现**

进一步固定逃逸方为 Search Only 策略，比较不同追捕方策略的捕获表现，结果如表 4-5 所示。该实验中逃逸方策略保持不变，因此捕获时间、捕获数量和追捕方回报的变化主要反映追捕方策略对追捕效果影响。

由表 4-5 和图 4-7 可以看出，在固定逃逸方为 Search Only 策略时，不同追捕方策略的捕获能力存在明显差异。随机追捕方在两类初始区域下均难以形成有效追击，其双目标捕获率均为 0，平均捕获数分别仅为 0.55 和 0.46，追捕方团队回报也为负值，说明随机动作无法有效应对具备搜索规避能力的逃逸方。

相比之下，Policy Only 追捕方在不进行在线搜索的情况下已经表现出较强的捕

表 4-5 固定逃逸方为 Search Only 时不同追捕方策略的对抗结果

| 初始区域 | 追捕方策略 | 总捕获率 (%)↑ | 双目标捕获率 (%)↑ | 平均捕获数↑ | 平均捕获时间 (步)↓ | 追捕方团队回报↑ | 追捕方单步耗时 (ms)↓ |
|---|---|---|---|---|---|---|---|
| $[-4,4]^2$ | Random | 55 | 0 | 0.55 | 23.02 | -0.053 | **0.10** |
| $[-4,4]^2$ | Policy Only | **100** | 88 | 1.88 | 11.08 | 1.423 | 0.33 |
| $[-4,4]^2$ | Search + Learning | **100** | 95 | 1.95 | 9.14 | 1.522 | 171.28 |
| $[-4,4]^2$ | Search Only | **100** | **100** | **2.00** | **6.94** | **1.669** | 1094.24 |
| $[-8,8]^2$ | Random | 46 | 0 | 0.46 | 23.39 | -0.264 | **0.09** |
| $[-8,8]^2$ | Policy Only | **100** | 85 | 1.85 | 13.13 | 1.304 | 0.27 |
| $[-8,8]^2$ | Search + Learning | 99 | **96** | **1.95** | 10.16 | **1.489** | 492.19 |
| $[-8,8]^2$ | Search Only | 95 | 95 | 1.90 | **9.09** | 1.455 | 846.15 |

获能力。在紧凑初始区域 $[-4,4]^2$ 下，其总捕获率达到 100%，双目标捕获率为 88%，平均捕获数为 1.88；在宽域初始区域 $[-8,8]^2$ 下，其双目标捕获率仍达到 85%，平均捕获数为 1.85。该结果说明，经过搜索专家动作蒸馏后的策略网络能够在单次前向推理条件下生成有效的追捕动作，相比随机策略具有显著优势。同时，Policy Only 的单步决策耗时仅为 0.33 ms 和 0.27 ms，具有较高的实时执行效率。

进一步分析 Search Only 可以发现，纯搜索追捕方在紧凑初始区域下取得最优捕获表现，其双目标捕获率达到 100%，平均捕获时间缩短至 6.94 步，追捕方团队回报达到 1.669，说明在初始距离较近、对抗过程较短的情况下，纯搜索能够充分发挥局势推演能力。然而，Search Only 的单步决策耗时达到 1094.24 ms，明显高于其他策略，表明纯搜索方法虽然能够提升捕获效率，但在线计算开销较大，难以满足高实时性部署需求。

Search + Learning 追捕方在捕获性能和计算开销之间表现出较好的折中。在 $[-4,4]^2$ 区域下，该方法的双目标捕获率为 95%，平均捕获时间为 9.14 步，追捕方团队回报为 1.522，虽然略低于 Search Only，但单步决策耗时仅为 171.28 ms。在 $[-8,8]^2$ 区域下，Search + Learning 的总捕获率、双目标捕获率、平均捕获数和团队回报均略高于 Search Only，同时单步决策耗时由 846.15 ms 降低至 492.19 ms。该结果表明，在宽域初始状态下，引入策略网络先验和价值网络评估能够提高有限搜索预算下的搜索有效性，使追捕方在保持较高捕获性能的同时降低在线决策开销。

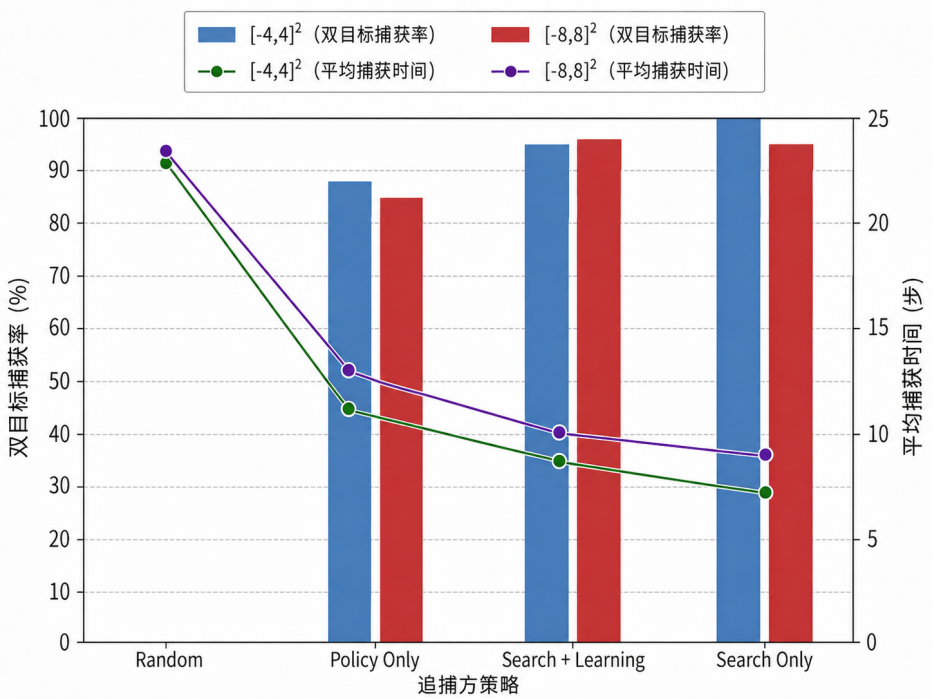



图 4-7 固定逃逸方为 Search Only 时不同追捕方策略的综合性能对比

综合两组固定对手实验可以看出，不同决策方法在性能和计算开销上各有特点。随机策略缺乏稳定的任务导向行为，仅适合作为最低性能基线；Policy Only 策略推理速度最快，并在追捕任务中明显优于随机策略，说明策略蒸馏能够有效提升策略网络的直接决策能力。Search Only 策略在部分场景下具有较强的局势推演能力，但单步决策耗时较大。相比之下，Search + Learning 策略通过引入策略网络先验和价值网络评估，在保持较好对抗表现的同时降低了纯搜索带来的计算开销，体现出搜索与学习融合方法在有限搜索预算下的综合优势。

### 4.4.4 搜索预算对决策性能的影响

在实际的多智能体对抗部署中，计算平台的算力往往是有限的。为了探究不同算法对在线计算资源的依赖程度，对纯搜索策略和搜索学习融合策略进行了搜索预算分析。

实验固定逃逸方为具备较强规避能力的 Search+learning 策略，逐步调整追捕方的单步搜索仿真次数。每组配置独立测试 200 局，对抗结果如表 4-6 所示。图 4-8 直观地展示了两类策略的双目标捕获率随搜索仿真次数的变化趋势。

结合表 4-6 与图 4-8 的数据，可以看出：在低搜索预算下，融合策略性能更稳定。

表 4-6 不同搜索预算下策略的对抗结果

| 追捕方策略 | 搜索仿真次数 | 总捕获率 (%)↑ | 双目标捕获率 (%)↑ | 平均捕获时间 (步)↓ | 追捕方团队回报 ↑ | 追捕方单步耗时 (ms)↓ |
|---|---|---|---|---|---|---|
| Search + Learning | 200 | **100** | 99 | 19.81 | 1.254 | 52.86 |
| Search + Learning | 500 | **100** | **100** | 16.40 | 1.360 | 217.89 |
| Search + Learning | 1000 | **100** | **100** | 15.90 | 1.407 | 597.06 |
| Search + Learning | 3000 | **100** | **100** | 14.30 | 1.455 | 1744.43 |
| Search + Learning | 5000 | **100** | **100** | 14.19 | 1.471 | 1900.28 |
| Search Only | 200 | 94 | 30 | 17.34 | 0.597 | **15.36** |
| Search Only | 500 | 97 | 77 | 16.41 | 1.059 | 48.14 |
| Search Only | 1000 | 96 | 83 | 12.92 | 1.167 | 301.28 |
| Search Only | 3000 | 99 | 99 | 12.01 | 1.426 | 1174.43 |
| Search Only | 5000 | **100** | **100** | **11.68** | **1.504** | 4031.14 |

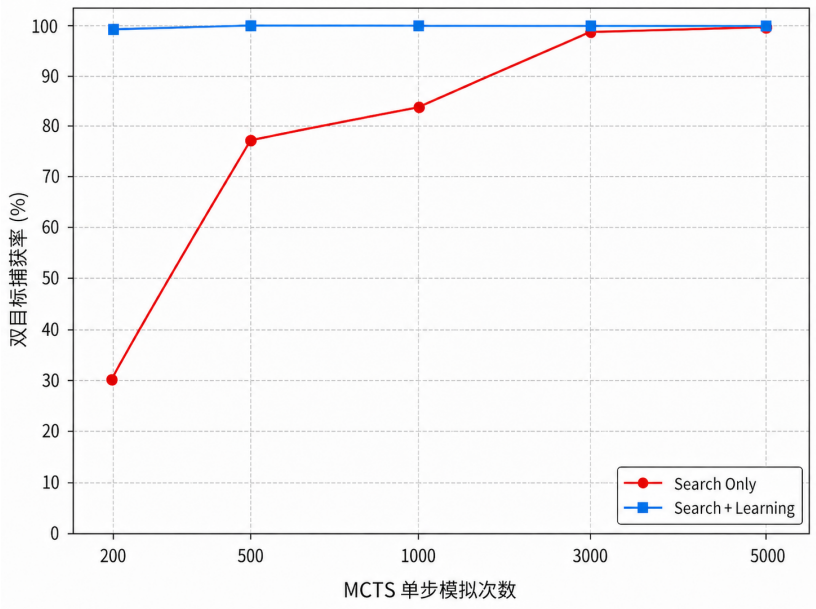



图 4-8 不同搜索预算下追捕方双目标捕获率变化曲线

当单步仿真次数降至 200 次时，Search Only 策略的性能出现断崖式下跌，双目标捕获率仅为 30%，团队回报降至 0.597；而 Search + Learning 策略依然保持了 99% 的捕获率和 1.254 的团队回报。在高搜索预算下，融合策略计算效率更高。当仿真次数增加到 5000 次时，两类策略的捕获率均接近 100%，但纯搜索策略的单步耗时高达 4031.14 ms，难以满足实时对抗需求。相比之下，Search + Learning 仅需 1000 次仿真即可达到同等捕获率，且单步耗时仅为 597.06 ms。

综合来看，Search + Learning 策略通过神经网络辅助评估，用极小的计算代价换取了稳定的高捕获率，在有限算力下显著提升了决策效率，更适合实际部署应用。

## 4.5 本章小结

本章围绕全局感知条件下的 2v2 多智能体追逃对抗任务，构建了搜索引导与策略网络蒸馏相结合的决策框架，对任务环境、状态表示、动作空间和奖励函数进行了建模。在实验部分，第四章从训练过程、对抗轨迹和不同决策方法对比等方面验证了所提方法的有效性。实验结果表明，策略网络能够在较低推理耗时下获得有效决策能力，而搜索学习融合方法能够在一定程度上兼顾对抗性能与在线计算开销，体现出神经网络辅助搜索在有限搜索预算下的应用价值，下一章将在本章方法基础上进一步研究局部感知条件下的多智能体追逃对抗策略。

# 第 5 章 面向真实场景的局部感知追逃对抗系统构建与仿真

第四章在全局感知假设下建立了二维连续空间中的 2v2 追逃对抗模型，并基于搜索引导与策略网络蒸馏方法开展了仿真实验。该设定较好地验证了融合策略在理想信息条件下的决策能力，但其仍建立在若干简化假设之上：策略模块能够直接获取全局状态；场景中无障碍物遮挡；高层动作未考虑底层轨迹规划及物理运动约束。因此，第四章侧重于验证对抗策略的理论上限，尚不能充分反映真实机器人系统在部署中面临的感知受限与动力学约束问题。

为进一步考察本文方法在实际部署条件下的可行性，系统在全局感知追逃场景的基础上，引入局部感知、障碍物约束以及底层轨迹规划机制，构建面向真实场景的局部感知追逃对抗系统。与全局感知不同，本章中每个机器人仅能通过自身局部观测获取环境信息。具体而言，机器人通过语义激光雷达感知有限视野内的队友、对手、障碍物和场地边界，并结合自身位置、速度等状态量形成局部观测编码。由此，策略网络的输入由全局状态向量转变为单机器人视角的局部观测特征。

同时，系统还会在二维场地中加入静态障碍物。障碍物一方面限制了机器人的可行运动区域，迫使智能体在博弈中主动避障；另一方面造成了视线遮挡，使观测信息呈现部分可观测特征。对于追捕方而言，障碍物可能阻断直线追击，需通过绕行或封堵形成压迫；对于逃逸方而言，障碍物既提供了掩体，也可能导致局部空间锁死。因此，障碍物的引入使追逃问题转化为带有环境拓扑约束的局部信息博弈。

此外，为使高层策略更贴近真实物理执行过程，系统不再将相对位移指令直接用于位置推进，而是引入基于最小控制代价（Minimum Control Effort，MINCO）的底层轨迹规划方法。高层策略依然输出面向局部目标的连续动作，随后经由轨迹规划模块转化为满足速度和加速度约束的平滑可行轨迹。系统在轨迹执行过程中更新机器人的运动学状态，从而建立起局部观测、高层决策、底层规划、状态更新的完整闭环仿真流程。

## 5.1 局部感知追逃场景与观测建模

在第四章场景的基础上，本节进一步构建局部感知条件下的追逃对抗模型。与前文相比，面向实际部署的系统建模变化体现在：第一，智能体基于自身视角提取局部观测；第二，引入障碍物并建立物理遮挡机制；第三，状态向量扩充归一化位姿

信息，为底层轨迹规划提供初值支撑。

局部感知场景采用二维连续有界区域 $\Omega$。本章引入静态矩形障碍物集合 $\mathcal{O}$，障碍物区域不可穿越，且会遮挡感知射线。设第 $i$ 个智能体在离散时刻 $k$ 的二维位置、速度和加速度向量分别为：

$$\mathbf{p}_{i,k} = [x_{i,k}, y_{i,k}]^T \in \mathbb{R}^2, \quad \mathbf{v}_{i,k} = [v_{i,k}^x, v_{i,k}^y]^T \in \mathbb{R}^2, \quad \mathbf{a}_{i,k} = [a_{i,k}^x, a_{i,k}^y]^T \in \mathbb{R}^2. \tag{5-1}$$

将运动学状态纳入系统后，记各智能体存活状态为 $z_{i,k} \in \{0,1\}$，全局状态 $s_k$ 扩展为 29 维。在局部感知设定下，智能体仅能通过自身观测函数 $\phi_i(\cdot)$ 获取观测向量 $o_{i,k}$：

$$o_{i,k} = \phi_i(s_k, \mathcal{O}) = [\mathbf{q}_{i,k}^T, \mathbf{l}_{i,k}^T]^T. \tag{5-2}$$

其中，$\mathbf{q}_{i,k}$ 为 8 维自身状态编码，$\mathbf{l}_{i,k}$ 为语义激光雷达观测编码。

**1. 自身状态编码**

自身状态编码用于提供机器人的运动指标与存活状态。为使神经网络更好地处理不同量纲的数据，系统对状态量进行了上下界归一化处理。特征向量 $\mathbf{q}_{i,k} \in \mathbb{R}^8$ 定义如下：

$$\mathbf{q}_{i,k} = [z_{i,k}, \bar{x}_{i,k}, \bar{y}_{i,k}, \bar{v}_{i,k}^x, \bar{v}_{i,k}^y, \bar{a}_{i,k}^x, \bar{a}_{i,k}^y, \bar{t}_k]^T. \tag{5-3}$$

其中，$z_{i,k}$ 为存活指示位，$\bar{x}_{i,k}, \bar{y}_{i,k}$ 为归一化后的全局位置坐标，$\bar{v}, \bar{a}$ 分别为归一化后的速度与加速度分量，$\bar{t}_k$ 为归一化后的剩余对抗时间。该编码确保了策略网络能够感知自身在场地中的相对位置及运动趋势，进而自适应地调整决策意图。

**2. 语义激光雷达观测建模**

系统通过模拟语义激光雷达获取周围环境信息，如图 5-1所示。局部感知以机器人当前位置为采样原点，在二维平面固定方向上发射 $N_b$ 条均匀分布的探测射线。设第 $m$ 条射线的固定方向角为 $\theta_m = 2\pi m / N_b$，其方向向量为 $[\cos\theta_m, \sin\theta_m]^T$。

该感知方式以当前位置为中心获取全局固定角度范围内的信息。探测对象分为队友、对手、障碍物和边界 $N_c = 4$ 个语义通道。对于语义类别 $c$，设第 $m$ 条射线探测到的目标距离为 $d_{m,c}$，最大探测量程为 $d_{\max}$。

在含障碍物环境中，需考虑障碍物的遮挡问题。若射线方向同时存在动态目标与静态障碍物，设目标距离为 $d_{\text{tar}}$，障碍物距离为 $d_{\text{obs}}$，则有效探测距离遵循如下截

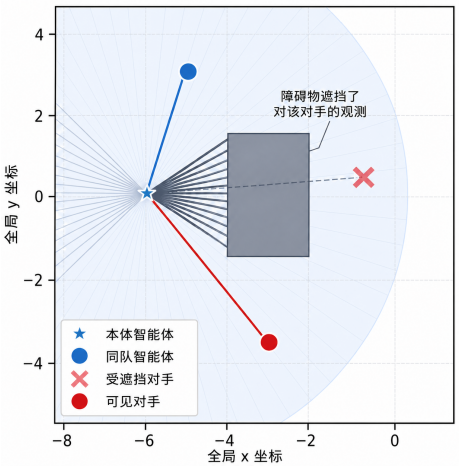
断逻辑：

$$d_{m,c}=\begin{cases} d_{\text{tar}}, & d_{\text{tar}} \le \min(d_{\text{obs}}, d_{\max}), \\ d_{\max}, & \text{其他}. \end{cases} \tag{5-4}$$

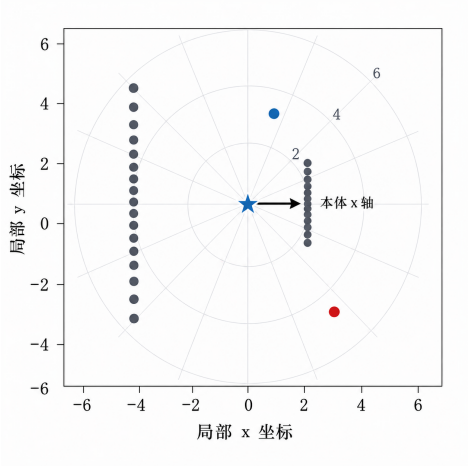
观测矩阵 $L_{i,k} \in \mathbb{R}^{N_b \times N_c}$ 的归一化形式定义为：

$$L_{i,k}(m,c)=\frac{d_{m,c}}{d_{\max}}. \tag{5-5}$$

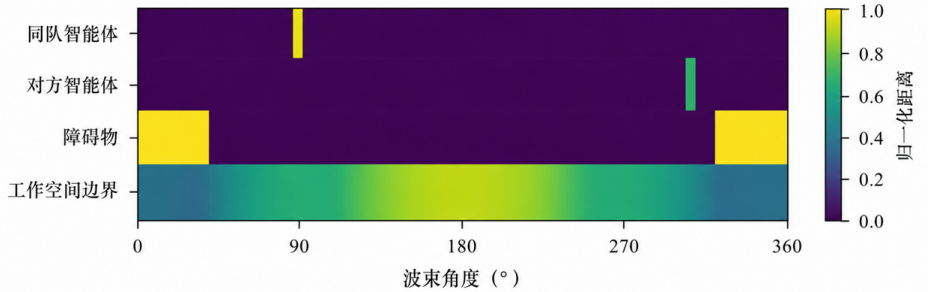
在此定义下，观测值越接近 0，表示对应语义目标距离智能体越近；观测值等于 1，则表示该方向在对应通道内未探测到有效目标。最终，观测矩阵展平后的向量 $\mathbf{l}_{i,k}$ 与自身状态拼接，形成维度为 264 的策略输入向量。该建模方法在保留核心语义要素的同时，通过视距受限和固定方向射线排布提升了仿真环境的物理逼真度。




（a）全局坐标系下的障碍遮挡关系




（b）本体局部坐标系下的观测表示




（c）语义激光雷达观测示意图

图 5-1 多智能体环境观测模型与坐标系表示

## 5.2 基于 MINCO 的底层轨迹规划

对于真实系统而言，高层策略给出的目标位置通常无法被底层电机瞬间执行。因此，在面向实际部署的局部感知场景中，系统引入基于 MINCO 的底层轨迹规划方法，在抽象的对抗策略与连续的机器人运动之间建立起平滑、可执行的控制接口。

高层策略网络依然输出二维连续动作指令。设第 $i$ 个智能体在时刻 $k$ 的位置为 $\mathbf{p}_{i,k}$，策略网络或搜索器输出的控制指令为 $\mathbf{u}_{i,k} \in \mathbb{R}^2$，则其对应的原始期望目标位置为：

$$\mathbf{p}_{i,k}^{\text{raw}} = \mathbf{p}_{i,k} + \mathbf{u}_{i,k}. \tag{5-6}$$

其中，$\mathbf{u}_{i,k}$ 表示高层策略期望在当前决策周期内产生的相对位移，$\mathbf{p}_{i,k}^{\text{raw}}$ 为底层轨迹规划的参考目标点。规划器将根据机器人当前的位置、速度和加速度，对该目标点进行动态可行性裁剪，并生成平滑的连续轨迹。

在底层规划中，机器人在二维平面内的轨迹采用五次多项式参数化表示。设单段轨迹时长为 $T_p$，对于任一时刻 $t \in [0, T_p]$，机器人的位置轨迹可定义为：

$$\mathbf{p}_i(t) = \sum_{r=0}^{5} \mathbf{c}_r t^r, \tag{5-7}$$

其中，$\mathbf{c}_r \in \mathbb{R}^{2\times 1}$ 为二维轨迹的多项式系数向量。将所有系数按行重组为矩阵 $\mathbf{C} = [\mathbf{c}_0, \mathbf{c}_1, \ldots, \mathbf{c}_5]^T \in \mathbb{R}^{6\times 2}$，并引入时间基函数列向量 $\boldsymbol{\beta}^{(0)}(t) = [1, t, t^2, t^3, t^4, t^5]^T \in \mathbb{R}^{6\times 1}$。为统一表示系统的高阶状态，对应速度基函数为 $\boldsymbol{\beta}^{(1)}(t)$，加速度基函数为 $\boldsymbol{\beta}^{(2)}(t)$，则轨迹的状态方程可紧凑写为：

$$\mathbf{p}_i(t) = \mathbf{C}^T \boldsymbol{\beta}^{(0)}(t), \tag{5-8}$$

$$\mathbf{v}_i(t) = \dot{\mathbf{p}}_i(t) = \mathbf{C}^T \boldsymbol{\beta}^{(1)}(t), \tag{5-9}$$

$$\mathbf{a}_i(t) = \ddot{\mathbf{p}}_i(t) = \mathbf{C}^T \boldsymbol{\beta}^{(2)}(t). \tag{5-10}$$

五次多项式能够完备地展示轨迹的二阶导数信息。对于给定的初始位置 $\mathbf{p}_{i,k}$、速

度 $\mathbf{v}_{i,k}$、加速度 $\mathbf{a}_{i,k}$，其初始多项式系数矩阵可由边界条件严格确定：

$$\mathbf{C}_{i,k}^{0}=\begin{bmatrix}\mathbf{p}_{i,k}^{T}\\ \mathbf{v}_{i,k}^{T}\\ \frac{1}{2}\mathbf{a}_{i,k}^{T}\\ \mathbf{0}_{1\times 2}\\ \mathbf{0}_{1\times 2}\\ \mathbf{0}_{1\times 2}\end{bmatrix}\in\mathbb{R}^{6\times 2}. \tag{5-11}$$

MINCO 轨迹规划的核心思想是在可行空间内搜寻控制代价最小的平滑曲线。针对平面移动机器人，系统以最小化 Jerk 作为惩罚项。设单段轨迹的控制阶数为 $r_c=3$，其控制代价定义为：

$$J=\int_{0}^{T_p}\left\|\mathbf{p}_i^{(3)}(t)\right\|_2^2\,dt. \tag{5-12}$$

在具体实现中，系统采用线性闭环更新机制。对于给定的可行目标位置 $\mathbf{p}_{i,k}^{\text{cmd}}$ 和当前系数状态 $\mathbf{C}_{i,k}$，规划器通过转移矩阵生成下一段轨迹系数：

$$\mathbf{C}_{i,k}^{+}=\mathbf{F}_{\text{cl}}\mathbf{C}_{i,k}+\mathbf{G}_{\text{cl}}(\mathbf{p}_{i,k}^{\text{cmd}})^{T}. \tag{5-13}$$

其中，$\mathbf{F}_{\text{cl}}$ 和 $\mathbf{G}_{\text{cl}}$ 为结合多项式边界约束与轨迹平滑性能要求，预先构造的常数闭环映射矩阵。

由于高层策略的决策频率低于底层电机的控制频率，系统采用滚动时域执行机制。设高层决策周期为 $\Delta t$，底层控制的时间片长度为 $\Delta t_c$，则单个决策步长内包含底层执行片段数为：

$$N_c=\frac{\Delta t}{\Delta t_c}. \tag{5-14}$$

实验中，取 $\Delta t=1,\Delta t_c=0.1$，即每个高层指令被分解为 10 个闭环控制周期。在该周期内，原始目标点 $\mathbf{p}_{i,k}^{\text{raw}}$ 保持锁定，但底层规划器会在每个 $\Delta t_c$ 起点根据自身最新的位置、速度和加速度重新求解轨迹。这种滚动修正机制大幅增强了系统抵抗物理扰动和跟踪高层指令的稳定性。

然而，策略网络输出的 $\mathbf{p}_{i,k}^{\text{raw}}$ 并不总是物理可达的。设智能体的速度与加速度上限分别为 $v_i^{\max}$ 和 $a_i^{\max}$。在生成轨迹前，系统需在规划视界内提取离散检查点 $t_j$，验

证其运动学可行性：

$$\|\dot{\mathbf{p}}_i(t_j)\|_\infty \le v_i^{\max}, \quad \|\ddot{\mathbf{p}}_i(t_j)\|_\infty \le a_i^{\max}. \tag{5-15}$$

同时，目标点必须处于物理场地边界内，即 $\mathbf{p}_{i,k}^{\mathrm{cmd}} \in \Omega$。综合上述极值与边界条件，底层规划器可计算出当前状态下，在离散检查点意义上满足速度、加速度和场地边界约束的目标可行区间 $[\underline{\mathbf{p}}_{i,k}, \overline{\mathbf{p}}_{i,k}]$。随后对原始目标进行逐维限幅裁剪：

$$\tilde{\mathbf{p}}_{i,k}^{\mathrm{cmd}} = \mathrm{clip}\left(\mathbf{p}_{i,k}^{\mathrm{raw}}, \underline{\mathbf{p}}_{i,k}, \overline{\mathbf{p}}_{i,k}\right). \tag{5-16}$$

值得强调的是，MINCO 模块仅处理时间维度的动力学约束与空间维度的边界限幅，静态障碍物碰撞并未作为硬约束写入 MINCO 的闭环轨迹生成过程和目标可行区间计算中。避障任务主要由高层策略网络通过处理语义激光雷达的局部观测信息来隐式学习。若高层策略决策失误导致碰撞，环境将直接判定状态越界并施加惩罚终止回合。

经过 $N_c$ 次底层闭环更新后，系统完成该高层决策周期的状态流转。更新方程可统一抽象为：

$$s_{k+1} = F_{\mathrm{MINCO}}(s_k, \mathbf{u}_k). \tag{5-17}$$

对于已失活的智能体，规划器中断其轨迹解算，位置冻结，速度与加速度强制归零。通过上述机制，本节建立起了一个严格受制于物理学规律的虚拟测试平台，使追逃对抗仿真真正具备了向真实系统迁移的工程价值。

## 5.3 实验结果与分析

### 5.3.1 实验参数与场景设置

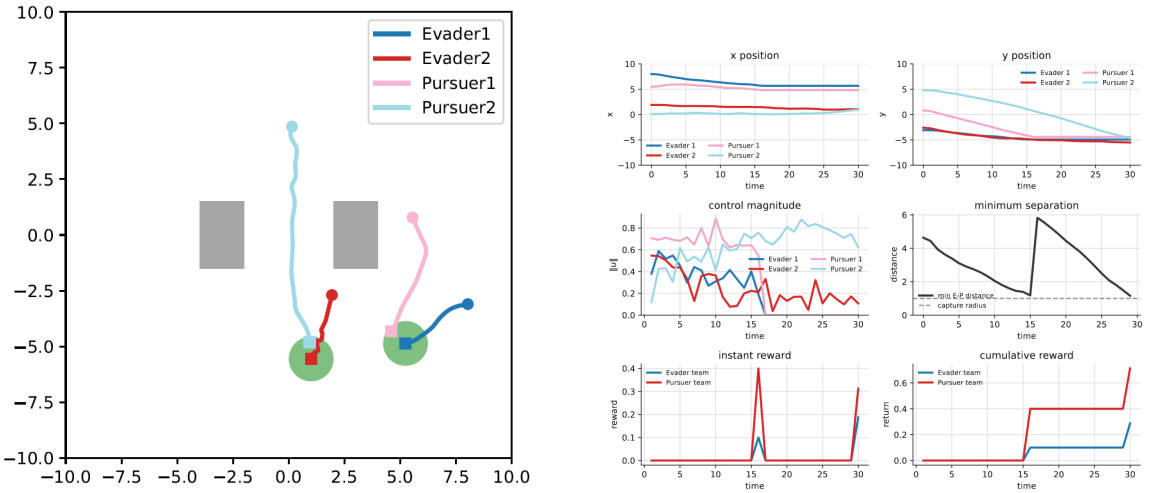
为验证局部感知、静态障碍物约束以及底层轨迹规划对 2v2 追逃对抗过程的影响，在面向真实场景的情况下开展仿真实验：智能体仅能通过语义激光雷达获取局部遮挡观测；环境中引入了静态障碍物；高层网络输出的位移指令需经过 MINCO 底层模块平滑转化为满足动力学约束的可执行轨迹。

实验的核心环境、感知与底层控制参数如表 5-1 所示。

在评价指标方面，除了沿用第四章的双目标捕获率、平均捕获时间、平均单步耗时等基础评价体系外，还引入了碰撞率这一指标。该指标指代因越界或与障碍物

表 5-1 局部感知与受限追踪对抗场景核心参数配置

| 参数名称 | 设定值 |
|---|---|
| 对抗区域界限 $\Omega$ | $[-10,10]\times[-10,10]$ |
| 最大对抗步数 $T$ | 80 |
| 高层决策周期 $\Delta t$ | 1 s |
| 智能体最大速度 $v^{\max}$ | 1.0 m/s |
| 智能体最大加速度 $a^{\max}$ | 1.0 m/s$^2$ |
| 激光雷达射线数量 $N_b$ | 64 |
| 障碍物数量设置 | 2（矩形障碍） |
| MINCO 底层执行片段长度 $\Delta t_c$ | 0.1 s |




（a）平面运动轨迹　　（b）状态、动作与奖励变化

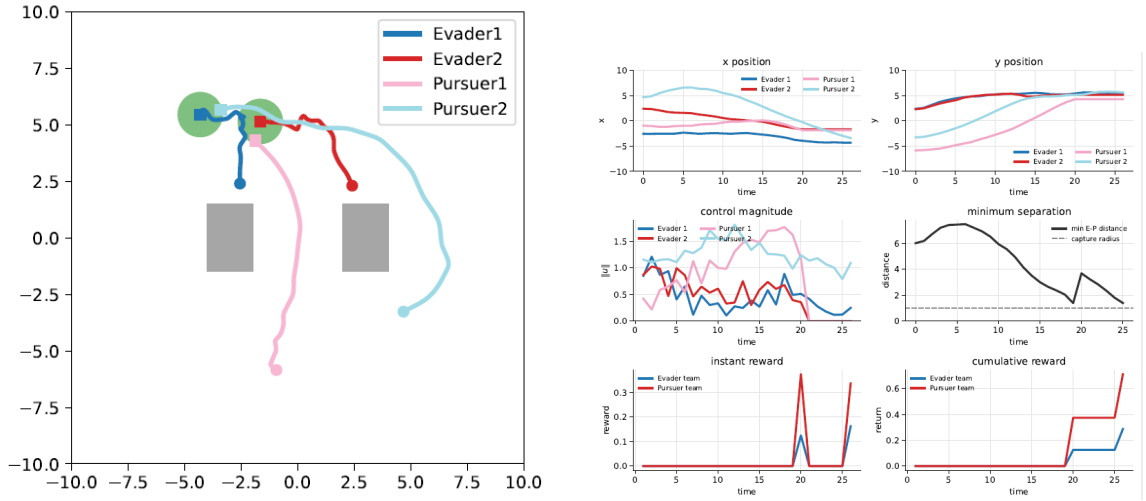
图 5-2 局部感知下的典型对抗轨迹 1

发生碰撞导致提前终止的对局比例，专门用于量化评估策略在复杂空间约束下的安全执行稳定性。

### 5.3.2 局部感知下的对抗轨迹分析

为直观评估局部感知、障碍物约束和底层轨迹规划对多智能体对抗行为的影响，本节从测试集中选取三组典型对抗轨迹进行分析。与第四章全局感知场景不同，本节中智能体无法直接获取完整环境状态，而是依靠带有遮挡效应的语义激光雷达形成局部观测；同时，高层策略输出的动作需要经过 MINCO 底层规划器转化为满足速度和加速度约束的连续轨迹。

图 5-2、图 5-3 和图 5-4 展示了局部感知与障碍物约束条件下的三组典型对抗轨迹。图中灰色矩形表示静态障碍物，蓝色和红色曲线分别表示两名逃逸方智能体，粉色和青色曲线分别表示两名追捕方智能体，圆点表示初始位置，方块表示终止位置，绿色圆形区域表示捕获判定范围。可以看出，引入障碍物后，追逃过程不再表现为无障碍场景中的直接接近，而是受到障碍物位置、局部观测范围和运动学约束的共同影响



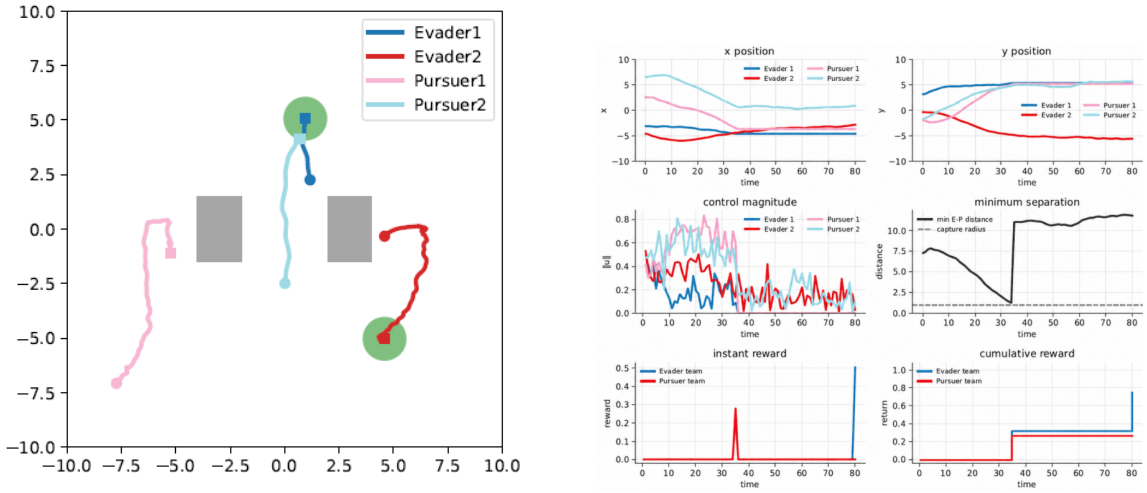

（a）平面运动轨迹　　（b）状态、动作与奖励变化

图 5-3 局部感知下的典型对抗轨迹 2

在图 5-2 和图 5-3 所示的对抗过程中，追捕方能够根据局部观测结果调整运动方向，通过绕行、穿插和多方向压迫逐步缩小逃逸方的活动空间，并在障碍物附近形成有效捕获。与全局无障碍场景相比，障碍物会阻断部分直线追击路线，使追捕方需要通过障碍物间隙或侧向区域接近目标；同时，逃逸方的逃跑路线也会被障碍物隔离切断。这说明局部观测输入能够为策略提供必要的环境语义信息，使智能体在障碍环境中仍能形成较为合理的追击和规避行为。

图 5-4 展示了逃逸方成功规避的一类典型情况。可以看出，在障碍物分隔和局部感知受限的共同作用下，追捕方难以始终保持对逃逸方的连续压迫；逃逸方则通过远离追捕方、保持安全距离以及利用障碍物附近空间进行机动，成功延长了自身存活时间。

图 5-5 给出了典型对抗轨迹 1 中四个智能体的速度与加速度变化曲线。图中连




（a）平面运动轨迹　　（b）状态、动作与奖励变化

图 5-4 局部感知下的典型对抗轨迹 3

续曲线表示 MINCO 底层规划器在控制周期内生成的内部采样结果，黑色叉号表示高层决策周期记录的离散状态点。可以看出，内部采样曲线与离散状态点整体保持一致，说明底层轨迹执行与高层状态更新之间具有较好的一致性。

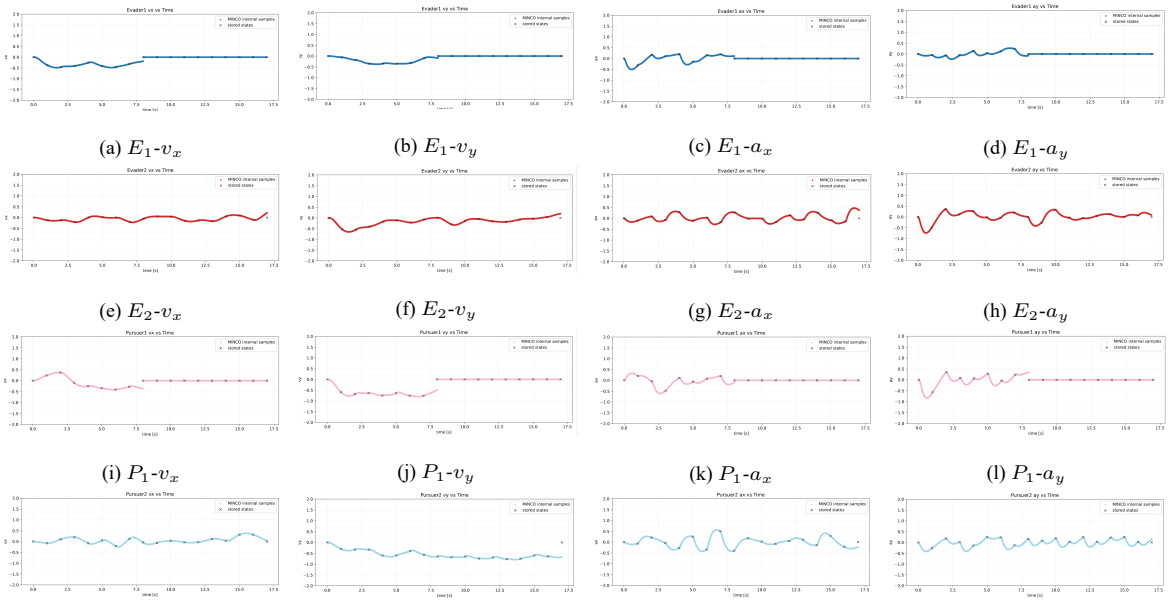
同时，各智能体的速度和加速度曲线整体变化连续，未出现明显阶跃突变或高频抖动。部分智能体在捕获失活后，其速度与加速度逐渐归零并保持不变。上述结果表明，MINCO 底层轨迹规划能够将高层策略输出的离散目标指令转化为较平滑的连续运动过程，从而提高局部感知追逃仿真与真实机器人执行过程之间的一致性。

### 5.3.3 感知受限与障碍约束对策略的影响

为分析真实场景约束对策略性能的影响，本节设置全局感知无障碍、局部感知无障碍和局部感知有障碍三组实验，结果如表5-2所示。三组实验均采用 Search + Learning 求解器，以突出感知形式和障碍物约束变化对对抗结果的影响。

由表5-2可见，在无障碍条件下，由全局感知切换为局部感知后，捕获性能并未明显下降。局部感知无障碍场景中的双目标捕获率为 100%，平均捕获数为 2.00，与全局感知无障碍场景基本一致，说明语义激光雷达观测在无障碍环境中能够为策略提供足够的相对位置信息。

引入障碍物后，策略性能明显下降。局部感知有障碍场景的总捕获率仍为 100%，但双目标捕获率降至 54%，平均捕获数降至 1.54，平均捕获时间增至 33.92 步。该结果表明，障碍物并未完全破坏追捕方的基本捕获能力，但显著增加了连续捕获两个



(a) $E_1$-$v_x$ (b) $E_1$-$v_y$ (c) $E_1$-$a_x$ (d) $E_1$-$a_y$

(e) $E_2$-$v_x$ (f) $E_2$-$v_y$ (g) $E_2$-$a_x$ (h) $E_2$-$a_y$

(i) $P_1$-$v_x$ (j) $P_1$-$v_y$ (k) $P_1$-$a_x$ (l) $P_1$-$a_y$

(m) $P_2$-$v_x$ (n) $P_2$-$v_y$ (o) $P_2$-$a_x$ (p) $P_2$-$a_y$

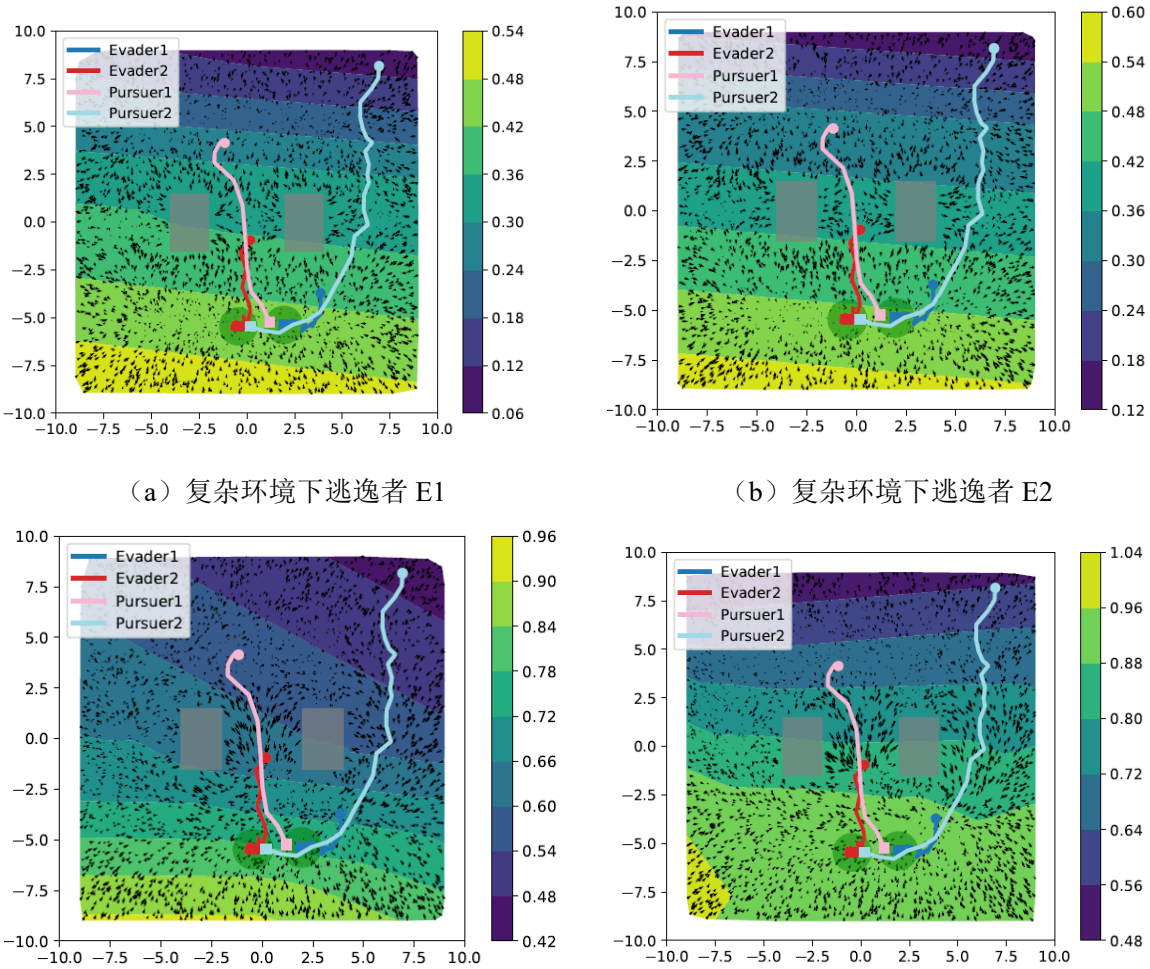
图 5-5 典型对抗轨迹 1 中底层轨迹的速度与加速度曲线

表 5-2 不同约束条件下的对抗结果

| 实验组别 | 求解器 | 总捕获率 (%)↑ | 双目标捕获率 (%)↑ | 平均捕获数↑ | 平均捕获时间 (步)↓ | 碰撞/出界率 (%)↓ |
|---|---|---|---|---|---|---|
| 全局感知无障碍 | Search + Learning | 100 | 99 | 1.99 | **15.90** | 0 |
| 局部感知无障碍 | Search + Learning | 100 | **100** | **2.00** | 16.21 | 0 |
| 局部感知有障碍 | Search + Learning | 100 | 54 | 1.54 | 33.92 | 0 |

逃逸目标的难度。其主要原因在于，障碍物同时带来运动路径绕行和局部观测遮挡，使追捕方在协同包抄、目标切换和残局追击中的决策难度增加。

三组实验的碰撞/出界率均为 0%，说明在当前设置下，局部感知策略能够结合底层轨迹规划保持较稳定的安全执行。总体来看，激光雷达感知本身对无障碍场景影响较小，而障碍物约束是导致策略性能下降的主要因素。




（a）复杂环境下逃逸者 E1　　（b）复杂环境下逃逸者 E2

（c）复杂环境下追捕者 P1　　（d）复杂环境下追捕者 P2

图 5-6 含障碍物环境下策略网络与价值网络输出的态势场可视化

图 5-6 提取了含障碍物场景下的网络态势场分布。图中灰色区域代表静态障碍物，背景等高线与颜色深度反映价值网络的局部收益评估，矢量箭头表示策略网络的动作引导先验。

对比第四章无障碍场景下的态势场可以发现，引入障碍物后，价值网络的输出

呈现出显著的地形依附特征。如图 5-6(a) 与 (b) 所示，逃逸方的价值场在障碍物边缘形成了明显的低势能安全区，策略场引导逃逸者利用障碍物作为掩体，规避追捕锋线；而在图 5-6(c) 与 (d) 中，追捕者的价值场在障碍物后方存在明显的低价值区，其策略场展现出绕行障碍物并重新向目标汇聚的特性。这表明系统所提出的算法框架仅依靠环境动力学推演与离线蒸馏，可使多智能体自发涌现出利用地形环境进行非对称博弈的高阶战术行为。

## 5.4 本章小结

本章在第四章基础上构建了面向真实场景的局部感知追逃对抗系统，通过引入语义激光雷达观测、静态障碍物约束以及 MINCO 底层轨迹规划模块，实现了部分可观测与机器人运动学约束下的平滑决策。典型对抗轨迹与对比实验表明，在局部观测和障碍物约束下，追逃双方表现出明显的绕行、遮挡与规避行为，MINCO 模块能有效将高层动作转化为平滑连续运动；尽管障碍物遮挡与通行约束增加了连续捕获难度、导致捕获性能有所下降，但零碰撞出界率验证了局部感知策略结合底层规划在复杂环境下的安全执行能力与基本可行性，也为未来进一步提升多机器人协同封堵与全局态势理解留下了空间。

# 结　论

本文围绕二维连续空间下的 2v2 多机器人追逃对抗问题，针对连续动作空间中联合决策维数高、在线搜索计算开销大以及学习策略训练稳定性不足等问题，开展了基于搜索引导与神经网络策略蒸馏的多机器人对抗策略研究。全文按照“问题建模—搜索求解—策略蒸馏—实验验证”的思路展开，构建了全局感知条件下的追逃对抗模型，设计了由蒙特卡洛树搜索、策略网络和价值网络组成的搜索—学习融合框架，并进一步面向实际部署约束，引入局部感知与底层轨迹规划进行验证。本文的主要工作总结如下：

(1) 建立了适用于二维连续空间的 2v2 多机器人追逃对抗模型。该模型将追捕方和逃逸方分别建模为由两个智能体组成的对抗团队，定义了包含位置、时间和存活状态的系统状态，并采用连续相对位移作为动作输入。在此基础上，结合捕获距离、一对一兑子机制、边界约束和最大对抗时长，构建了状态转移、奖励函数与终止判定方法。该建模方式既能够反映连续空间中追逃双方的动态交互过程，又能够刻画团队协同与队间对抗共同作用下的局势演化，为后续算法设计和实验分析提供了统一基础。

(2) 提出了基于搜索引导与策略蒸馏的多智能体对抗策略生成方法。针对纯搜索方法在线计算开销较大的问题，本文利用蒙特卡洛树搜索进行多步前向推演，生成具有长期收益考虑的专家动作；随后通过行为克隆将专家动作蒸馏到去中心化策略网络中，使网络能够在在线阶段快速输出连续动作；同时训练价值网络估计对抗状态的长期回报，并用于辅助搜索过程中的叶节点评估。由此形成了“搜索生成专家样本、网络学习搜索经验、网络反向辅助搜索”的闭环机制，在一定程度上兼顾了搜索方法的决策质量和神经网络策略的执行效率。

(3) 全局感知条件下的实验结果表明，所提方法能够有效提升多机器人追逃对抗中的决策性能。本文成功构建了 160K 条等效对抗轨迹数据集，策略网络单步推理耗时仅 0.33ms；与纯搜索策略相比，融合策略在有限预算下降低了无效扩展，显著提高了决策效率。实验中的典型轨迹表明，追捕方能够形成协同包夹、目标切换和封堵拦截等行为，逃逸方也能够表现出周旋规避和延长存活时间的策略特征，说明本文方法能够在连续追逃对抗场景中生成较合理的对抗策略。

(4) 构建了面向真实场景的局部感知追逃仿真系统。通过引入语义激光雷达观测、静态障碍物遮挡以及 MINCO 底层轨迹规划，本文将高层对抗策略输出转化为满足运动约束的可执行轨迹。结果表明，在局部感知有障碍约束场景下，系统仍实现了 54% 的双目标捕获率；同时，全局碰撞出界率保持为 0%，说明本文方法在受限感知和运动约束条件下具有高安全性和部署可行性。。

综上所述，本文提出的搜索引导与神经网络策略蒸馏方法能够较好地应用于连续空间下的多机器人追逃对抗任务。该方法利用搜索生成高质量专家决策，利用神经网络实现策略压缩与快速推理，并通过价值估计提高搜索效率，为多机器人对抗决策中搜索方法与学习方法的融合提供了一种可行思路。

受研究时间和实验条件限制，本文仍存在一些不足。当前研究主要面向 2v2 追逃对抗场景，智能体规模和环境复杂度仍较为有限；策略训练依赖高预算搜索生成专家样本，数据获取成本较高；局部感知场景中尚未引入通信机制和历史记忆结构，对遮挡目标和全局态势的推断能力仍有提升空间。后续研究可进一步扩展到更多智能体、更复杂障碍环境和异构机器人平台，并结合图神经网络、注意力机制、自博弈训练和真实机器人实验，提升算法的泛化能力、实时性和工程适用性。

# 参考文献

[1] 迟嵩禹, 李帅, 王晨, 等. 追逃博弈问题研究综述[J]. 自动化学报, 2025, 51(4): 705-726.

[2] Isaacs R. Differential Games: A Mathematical Theory With Applications to Warfare and Pursuit, Control and Optimization[M]. New York: John Wiley & Sons, Inc., 1965.

[3] Ho Y C. Differential games, dynamic optimization, and generalized control theory[J]. Journal of Optimization Theory and Applications, 1970, 6(3): 179-209.

[4] Flynn J. Lion and man: The general case[J]. SIAM Journal on Control, 1974, 12(4): 581-597.

[5] Oyler D W, Kabamba P T, Girard A R. Pursuit-evasion games in the presence of a line segment obstacle[C]//Proceedings of the 53rd IEEE Conference on Decision and Control (CDC). Los Angeles, USA: IEEE, 2014: 1149-1154.

[6] Garcia E, Casbeer D W, Pachter M. Optimal strategies for a class of multi-player reach-avoid differential games in 3D space[J]. IEEE Robotics and Automation Letters, 2020, 5(3): 4257-4264.

[7] Bakolas E. Evasion from a group of pursuers with double integrator kinematics[C]//Proceedings of the 52nd IEEE Conference on Decision and Control. Firenze, Italy: IEEE, 2013: 1472-1477.

[8] Selvakumar J, Bakolas E. Evasion from a group of pursuers with a prescribed target set for the evader [C]//Proceedings of the American Control Conference (ACC). Boston, USA: IEEE, 2016: 155-160.

[9] Coon M, Panagou D. Control strategies for multiplayer target-attacker-defender differential games with double integrator dynamics[C]//Proceedings of the 56th IEEE Annual Conference on Decision and Control (CDC). Melbourne, Australia: IEEE, 2017: 1496-1502.

[10] Kokolakis N M T, Vamvoudakis K G. Bounded rational Dubins vehicle coordination for target tracking using reinforcement learning[J]. Automatica, 2023, 149: 110732.

[11] Zhu H. Optimal Control of Spacecraft Orbital Pursuit-evasion Based on Differential Game[D]. China: National University of Defense Technology, 2017.

[12] Wang J N, Li G L, Liang L, et al. Pursuit-evasion games of multiple cooperative pursuers and an evader: A biological-inspired perspective[J]. Communications in Nonlinear Science and Numerical Simulation, 2022, 110: 106386.

[13] Lin B, Qiao L, Jia Z H, et al. Control strategies for target-attacker-defender games of USVs[C]// Proceedings of the 6th International Conference on Automation, Control and Robotics Engineering (CACRE). Dalian, China: IEEE, 2021: 191-198.

[14] Sani M, Robu B, Hably A. Pursuit-evasion Game for Nonholonomic Mobile Robots With Obstacle Avoidance using NMPC[C]//Proceedings of the 28th Mediterranean Conference on Control and Automation (MED). IEEE, 2020.

[15] Santos R F D, Ramachandran R, Vieira M A M, et al. Parallel multi-speed Pursuit-Evasion Game algorithms[J]. Robotics and Autonomous Systems, 2023, 163: 104382.

[16] Levchenkov A Y, Pashkov A G. Differential game of optimal approach of two inertial pursuers to a noninertial evader[J]. Journal of Optimization Theory and Applications, 1990, 65(3): 501-518.

[17] Chen J, Zha W, Peng Z H, et al. Multi-player pursuit-evasion games with one superior evader[J]. Automatica, 2016, 71: 24-32.

[18] Hollinger G, Singh S, Kehagias A. Improving the Efficiency of Clearing with Multi-agent Teams [J]. The International Journal of Robotics Research, 2010, 29(8): 1088-1105.

[19] Garcia E, Casbeer D W, von Moll A, et al. Multiple pursuer multiple evader differential games[J]. IEEE Transactions on Automatic Control, 2021, 66(5): 2345-2350.
[20] Wei M, Chen G S, Cruz J B, et al. Multi-pursuer multi-evader pursuit-evasion games with jamming confrontation[J]. Journal of Aerospace Computing, Information, and Communication, 2007, 4(3): 693-706.
[21] Wei M, Chen G S, Cruz J B, et al. A decentralized approach to pursuer-evader games with multiple superior evaders in noisy environments[C]//Proceedings of the IEEE Aerospace Conference. Big Sky, USA: IEEE, 2007: 1-10.
[22] Pierson A, Wang Z J, Schwager M. Intercepting rogue robots: An algorithm for capturing multiple evaders with multiple pursuers[J]. IEEE Robotics and Automation Letters, 2017, 2(2): 530-537.
[23] Greenfeld I. A differential game of surveillance evasion of two identical cars[J]. Journal of Optimization Theory and Applications, 1987, 52(1): 53-79.
[24] Lopez V G, Lewis F L, Wan Y, et al. Solutions for multiagent pursuit-evasion games on communication graphs: Finite-time capture and asymptotic behaviors[J]. IEEE Transactions on Automatic Control, 2020, 65(5): 1911-1923.
[25] Mamino M. On the computational complexity of a game of cops and robbers[J]. Theoretical Computer Science, 2013, 477: 48-56.
[26] Karaman S, Frazzoli E. Incremental Sampling-Based Algorithms for a Class of Pursuit-Evasion Games[G]//Springer Tracts in Advanced Robotics: Algorithmic Foundations of Robotics IX: vol. 68. Berlin, Heidelberg: Springer, 2010: 71-87.
[27] Sugihara K, Suzuki I. Optimal algorithms for a pursuit-evasion problem in grids[J]. SIAM Journal on Discrete Mathematics, 1989, 2(1): 126-143.
[28] Dawes R W. Some pursuit-evasion problems on grids[J]. Information Processing Letters, 1992, 43(5): 241-247.
[29] Guy R K. Unsolved problems in combinatorial games[G]//Combinatorics Advances. Boston: Springer, 1995: 161-179.
[30] Bopardikar S D, Bullo F, Hespanha J P. Sensing limitations in the lion and man problem[C]// Proceedings of the American Control Conference (ACC). New York, USA: IEEE, 2007: 5958-5963.
[31] Bopardikar S D, Bullo F, Hespanha J P. Cooperative pursuit with sensing limitations[C]// Proceedings of the American Control Conference (ACC). New York, USA: IEEE, 2007: 5394-5399.
[32] Kehagias A, Hollinger G, Singh S. A graph search algorithm for indoor pursuit/evasion[J]. Mathematical and Computer Modelling, 2009, 50(9–10): 1305-1317.
[33] Kehagias A, Papazoglou A C. An Algorithm for Limited Visibility Graph Searching[EB/OL]. 2021.
[34] Li A Q, Fioratto R, Amigoni F, et al. A Search-Based Approach to Solve Pursuit-Evasion Games with Limited Visibility in Polygonal Environments[J]. 2018.
[35] Zhang Z, Smereka J M, Lee J, et al. Game tree search for minimizing detectability and maximizing visibility[J]. Autonomous Robots, 2021.
[36] Zhang Z, Sung Y, Zhou L, et al. Tree Search Techniques for Minimizing Detectability and Maximizing Visibility[C]//Proceedings of the IEEE International Conference on Robotics and Automation (ICRA). Montreal, Canada: IEEE, 2019.
[37] Bonanni L, Meli D, Castellini A, et al. Monte Carlo Tree Search with Velocity Obstacles for safe and efficient motion planning in dynamic environments[EB/OL]. 2025.
[38] Li Q, Wang F, Liu Z, et al. Air combat manoeuvre strategy algorithm based on two-layer game

decision-making and the distributed MCTS method with double game trees[J]. Systems Science & Control Engineering, 2022, 10(1): 811-821.

[39] Chen J, Baskaran A, Zhang Z, et al. Multi-Agent Reinforcement Learning for Visibility-based Persistent Monitoring[C]//Proceedings of the IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS). Prague, Czech Republic: IEEE, 2021: 2563-2570.

[40] Qin X, Jiao Z, Zhang P, et al. Multi-Agent Cooperative Target Search Based on Reinforcement Learning[J]. Journal of Physics: Conference Series, 2020, 1549(2): 022104.

[41] Hsu C D, Jeong H, Pappas G J, et al. Scalable Reinforcement Learning Policies for Multi-Agent Control[EB/OL]. 2020.

[42] Souidi M E H, Siam A, Pei Z, et al. Multi-Agent Pursuit-Evasion Game Based on Organizational Architecture[J]. Journal of Computing and Information Technology, 2019, 27(1): 1-11.

[43] Shi G, Zhou L, Tokekar P. Robust Multiple-Path Orienteering Problem: Securing Against Adversarial Attacks[J]. IEEE Transactions on Robotics, 2023, 39(3): 2060-2077.

[44] Agmon N. Robotic Strategic Behavior in Adversarial Environments[C]//Proceedings of the Twenty-Sixth International Joint Conference on Artificial Intelligence. Melbourne, Australia: International Joint Conferences on Artificial Intelligence Organization, 2017.

[45] Riviere B, Hoenig W, Anderson M, et al. Neural Tree Expansion for Multi-Robot Planning in Non-Cooperative Environments[EB/OL]. 2021.

[46] Zhang H, Zhou H, Wei Y, et al. Autonomous maneuver decision-making method based on reinforcement learning and Monte Carlo tree search[J]. Frontiers in Neurorobotics, 2022, 16.

[47] Coulom R. Efficient Selectivity and Backup Operators in Monte-Carlo Tree Search[C]//Lecture Notes in Computer Science: Computers and Games: vol. 4630. Berlin, Heidelberg: Springer, 2007: 72-83.

[48] Chaslot G M J B, Winands M H M, van den Herik H J, et al. Progressive Strategies for Monte-Carlo Tree Search[J]. New Mathematics and Natural Computation, 2008, 4(03): 343-357.

[49] Auger D, Couëtoux A, Teytaud O. Continuous Upper Confidence Trees with Polynomial Exploration—Consistency[C]//Lecture Notes in Computer Science: Machine Learning and Knowledge Discovery in Databases: vol. 8188. Berlin, Heidelberg: Springer, 2013: 194-209.

# 致　谢

岁月不居，时节如流。回望大学四年的求学时光，许多画面仍历历在目。值此毕业论文完成之际，我想向所有在本科阶段给予我帮助、支持与陪伴的老师、同学、朋友和家人，致以最诚挚的感谢。

我要衷心感谢我的导师邓方教授。邓老师学识渊博、治学严谨。在我完成本科毕设的过程中，邓老师不仅为我提供了实验场地与实验设备，而且也在组会上留出时间关注我的毕设进度，给出我未来工作的建议，在我困惑时给予我解答，教会我如何进行研究，更教会我如何面对困难、如何保持对学术的热情和追求。

同时，我也要特别感谢课题组的老师和同学们。特别感谢孙智昊师兄，从最初的选题与调研，到后续实验方案的调整与代码的的修改和答疑解惑，再到撰写论文的指导和修改都给予了我非常多具体而细致的帮助。此外，我还要感谢张乐乐老师、石翔老师，黄璟涛师兄、姚继宇师兄、王延朋师兄、刘文彬师兄、方辰宇师兄、陈光宇师兄、尤尚游师兄，还有我的同门陈浩、赖卓群、徐帅意。你们在我科研入门过程中耐心地给予我无私的帮助和指导，让我真切感受到课题组温暖而踏实的氛围。

我也想感谢一路陪伴我的同学、舍友和朋友们。感谢我的舍友王昊楠、王润东、吕翀以及大学朋友们对我的包容与陪伴。感谢愿意倾听、陪我放松解压的老朋友徐健涵、聂雨博、于济航。感谢陪伴我、在我情绪波动时给我鼓励并让我坚定信心的大学朋友们。大学四年中正是因为有你们，许多普通的日子才变得鲜活而难忘。

最后，感谢我的父母二十余载对我的栽培以及生活中的爱与支持。每当我遇到困难，父母总是第一个给我鼓励的人。感谢这么多年来你们无怨无悔的付出，永不停歇的照顾。你们是我求学路上最大的底气，你们的充分信任，让我勇敢大胆的做出生命中的每一个选择。

行文至此，百感交集，大学四年的时光也即将画上句号。毕业不是终点，而是新的开始。未来道路或许仍有迷茫与挑战，但我会带着这段时光中收获的温暖、勇气与力量，继续坚定地走下去。再次由衷地感谢这段时间里陪伴帮助过我的人！